

Paper_PTA — Come imposterei il progetto se ripartissi da zero

Report di revisione complessiva. Sessione Opus, 2026-06-13. Nessun file esistente è stato modificato: questo è un documento autonomo. Obiettivo: dire, in modo ordinato, cosa farei se dovessi ricominciare il progetto da foglio bianco, alla luce di tutto ciò che ora esiste (dati, codice, letteratura).

0. Sintesi in un paragrafo

Il progetto, così come è impostato, prova a stimare l'effetto della “**profondità**” delle **clausole ambientali (EP depth)** sui **flussi di export cinesi**. Dopo aver guardato i dati a fondo, la mia conclusione è netta: **questa domanda, con questi dati, non è identificabile — e il null che è già emerso non è un fallimento dell'analisi, è la risposta corretta a una domanda mal posta**. La variazione di trattamento è troppo povera (14 accordi, di cui l'ASEAN da solo copre 11 destinazioni con valori identici, e quasi nessuna variazione *within-country* nel tempo) e il “depth” è collineare con il PTA stesso e con la profondità complessiva dell'accordo. Se ripartissi da zero **non cambierei i dati grezzi, cambierei la domanda**: passerei da “quanto export in più/in meno” a “**come cambia la composizione** (green vs dirty) dell'export di una stessa impresa verso una stessa destinazione”. È l'unica cosa che questi dati possono identificare in modo credibile, ed è anche quella che dialoga con la letteratura di riferimento (Brandi 2020, Abman-Lundberg-Ruta 2024, Cherniwchan 2017, Shapiro 2021). Il ridisegno §7 del ROADMAP va già in questa direzione: questo report lo conferma e aggiunge tre cose che ritengo decisive — un **trattamento guidato dal meccanismo** (non un conteggio), un **panel collassato** per l'analisi principale (che elimina alla radice i crash che hanno bruciato intere sessioni), e una **costruzione del trattamento da tabella tidy** invece che da vettori posizionali hardcoded.

1. Cosa ho guardato

Per non darti un giudizio “a sensazione”, ecco la base su cui poggia questo report:

- **Pipeline dati completa:** 1_Build_..._.R (costruzione indici da WB+TREND), 2_Build_..._.do (merge con i dati doganali cinesi + lista OECD green), 3_Build_..._.R (conversione/compressione in .fst).
- **Struttura reale del trattamento:** Data/Merged/Merged_TREND_WB_Indices_Only.csv (250 country-year), che mostra il trattamento *effettivo* riga per riga.

- **Codice di analisi:** `pta_functions.R`, `OLS_HDFE.R`, e i nuovi script del ridisegno (`02_data_hygiene_audit`, `04_wits_pref_tariffs`, `05_dirty_goods`, `06_total_depth`, `07_triple_diff`).
- **Risultati:** la ladder (`OLS_Ladder_FE.tex`) e le tabelle originali con interazione `env_good` (`OLS_TREND_Interaction_fpt_fpd.tex`).
- **Letteratura:** l'indice del wiki di progetto (Brandi, ALR 2024, Shapiro, Cherniwchan, Copeland-Shapiro-Taylor, Neri-Laine, ecc.).
- **Il .fst:** 15 GB, 49 M righe, $\text{impresa} \times \text{HS6} \times \text{destinazione} \times \text{anno}$.

2. La diagnosi di fondo: tre problemi, in ordine di gravità

2.1 Identificazione — il trattamento non ha abbastanza variazione (e quella che c'è è confusa)

Guardando `Merged_TREND_WB_Indices_Only.csv`, il quadro è inequivocabile:

- Per **quasi ogni destinazione la depth è costante nel tempo** dopo l'entrata in vigore. Solo 3 paesi cambiano valore nel periodo (Corea 133: salta a 72 nel 2015; un paio d'altri).
- **11 destinazioni hanno valori identici** (TREND=4, WB=6): sono i membri ASEAN, cioè *un solo accordo* contato 11 volte.
- La variazione utile si riduce quindi a **14 accordi**, con timing scaglionato.

Questo ha tre conseguenze che si sommano:

1. Il “depth” come **trattamento continuo** è una finzione: ci sono ~14 valori distinti assegnati a livello di accordo, non un continuum. Stimarne un coefficiente lineare e interpretarlo “per unità di depth” non ha un significato chiaro.
2. La depth è **collineare con il PTA stesso** (entra in vigore quando entra il PTA) e con la **profondità totale** dell'accordo. Salendo la scala di FE l'effetto si azzerà in modo monotono (la ladder lo mostra: `fpt+fpd` dà 0.0003, p 0.9): è la firma di una **selezione**, non di un effetto causale. Le “stelle” sopravvivono solo nella specifica meno satura e clusterizzata in modo troppo fine.
3. L'inferenza onesta ha **~14 cluster**, non i 3.500 (dt) o i milioni (pdt) usati finora. Con così pochi cluster servono metodi dedicati (wild bootstrap a pochi cluster, randomization inference), non l'asintotica standard.

2.2 Meccanismo — perché mai gli EP dovrebbero muovere l'export cinese?

Questo problema è più profondo dell'econometria e va affrontato *prima*. La Cina è l'**esportatore** in tutti questi flussi. Perché una clausola ambientale in un accordo Cina-X dovrebbe cambiare l'export cinese verso X? I canali plausibili sono pochi e specifici:

- **Green market access** (taglio tariffario sui beni ambientali) → ↑ export green cinese. Canale diretto, ma è esattamente quello che l'interazione `env_good` misura — e nei dati è minuscolo e di segno *negativo* (-0.0005^*).
- **Standard / non-regression** → ↑ costi per i produttori dirty → ↓ export dirty (pollution-haven al contrario, à la Brandi).
- **Tutto il resto** (regulatory space, cooperazione, clausole soft): **nessun meccanismo commerciale**.

Il punto cruciale: l'indice di **depth somma insieme provvedimenti con meccanismo e provvedimenti senza**. Così facendo *diluisce meccanicamente* qualunque effetto reale verso lo zero. Una parte del null potrebbe quindi essere un **artefatto della costruzione del trattamento**, non assenza vera di effetto. Da zero, il trattamento va costruito **dal meccanismo**, non come conteggio.

2.3 Costruzione del trattamento — fragile e basata su posizioni

`1_Build_..._R` costruisce il trattamento con: - liste di paesi **hardcoded a mano**, - vettori `Year_WB <- c(2005, 2002, ...)` **posizionali** (l'anno dell'accordo *j*-esimo dipende dall'ordine delle colonne), - rimozione manuale di righe-capitolo (`df_wb[-c(1, 7, 15, 20, ...)]`), - aggregazione **max** tra accordi quando un paese è in più di uno.

Basta uno sfasamento di una posizione nel vettore `Year_WB` per **corrompere silenziosamente tutto il timing** senza alcun errore. È il tipo di fragilità che non si nota finché non invalida un paper. Da zero, il trattamento si costruisce da **una sola tabella tidy** (un accordo per riga: partner, anno di entrata, provvedimenti...) unita per chiave, mai per posizione.

A questo si aggiungono problemi-dati che possono invalidare il progresso e vanno chiusi prima di ogni stima: - **Concordanza HS6 sulle revisioni 2002/2007/2012** (il problema più pericoloso: se i prodotti non sono riportati a una sola vintage HS, gli FE `fpd/fpt` spezzano le serie e `env_good` è mal assegnato). - **Tariffa**: oggi si usa la **MFN**, non la **preferenziale bilaterale** — ed è l'unica variabile “robusta”, quindi l'unica cosa che “funziona” è anche mal specificata. - **Hong Kong + Macao** (entrepôt + CEPA) da escludere dalla specifica principale. - **Dirty goods assenti**: c'è solo la lista green OECD; senza intensità emissiva per HS6 l'ipotesi pollution-haven non è testabile.

3. Come imposterei il progetto da zero

3.1 La domanda di ricerca

Abbandonerei “qual è l'effetto della **EP depth** sul volume di export” (non identificabile, e già null). La sostituirei con una domanda di **composizione/riallocazione**, che gli stessi dati possono reggere:

Quando entra in vigore un PTA cinese con clausole ambientali, **l'impresa cinese sposta il proprio paniere di export verso quella destinazione** verso i beni green (e/o lontano dai beni dirty), rispetto ai beni neutri?

Due livelli, dal più robusto al più ambizioso: - **Composizione cross-prodotto** (baseline): green/dirty vs neutri, *entro* impresa-dest-anno. - **Riallocazione within-firm** (potenziale risultato da top journal): la quota di green nel paniere di una stessa impresa multiprodotto verso una stessa destinazione. È il margine che dialoga con Cherniwchan (2017) e che nessuno ha ancora mostrato per la Cina.

3.2 Il trattamento — guidato dal meccanismo, a livello di accordo, onesto

1. **Una tabella accordi tidy** (14 righe WB / 15 TREND): **agreement**, **partner**, **entry_year**, e poi le componenti. Tutto il resto si deriva da qui via join.
2. **Componenti teoriche, non un conteggio.** Tre categorie predichiarate, scelte perché hanno un meccanismo commerciale:
 - **GreenMarketAccess** → ipotesi su export **green**;
 - **Standards/NonRegression** → ipotesi su export **dirty**;
 - **Enforcement** (hard vs soft) come moderatore. Il resto (regulatory space, cooperazione) entra solo come **placebo** (non dovrebbe avere effetto: se ce l'ha, è selezione).
3. **TotalDepth non-ambientale sempre accanto** (lo script 06_total_depth.R lo costruisce già, con validazione interna): è l'unico modo per separare “clausole ambientali” da “accordo profondo in generale”.
4. **Depth come ordinale/binario**, non cardinale: la somma di provvedimenti eterogenei non ha unità interpretabile. Il binario “ha EP green / non ha” è più difendibile del conteggio.

3.3 Le fondamenta dati (da chiudere *prima* di ogni stima)

In ordine di priorità: 1. **Concordanza HS6** a una sola vintage (es. HS 2002) per tutto il 2000–2015. Decisivo. 2. **Green/dirty**: **env_good** (OECD CLEG) per il green; **Shapiro 2021 (intensità CO2, continua)** come misura principale del dirty, con Mani-Wheeler binario come robustezza. Verificare overlap green dirty 0. 3. **Tariffe preferenziali AHS** bilaterali Cina→partner da **WITS TRAINS** (lo script 04_wits_pref_tariffs.R è già impostato) al posto della MFN. 4. **Escludere HK + Macao** dalla main; robustezza con inclusione. 5. **Consistenza companyID** attorno al 2004 (liberalizzazione dei trading rights).

3.4 L'identificazione

- **Specifica principale (triple-diff sulla composizione)** — esattamente la §7.1, che è corretta:

```
ln_export ~ EP:green_p + EP:dirty_p + TotalDepth:green_p + TotalDepth:dirty_p  
          | fpd + fdt + pt,    cluster = ~accordo
```

L'FE fdt assorbe **tutto** ciò che varia a impresa-dest-anno (incluso il PTA, la dimensione del mercato, la selezione): il confound della §2.1 sparisce per costruzione. L'identificazione viene dal **confronto tra prodotti green/dirty e neutri entro la stessa impresa-dest-anno**.

- **Il centro di gravità del paper è l'event study**, non un coefficiente: leads/lags dell'entrata $PTA \times \text{green/dirty}$ (`sunab()` per il timing scaglionato). Un grafico senza pre-trend differenziali e con un salto a $t=0$ è la prova credibile; una tabella di coefficienti no.
- **Inferenza a livello di accordo**. Anche `country_code` è troppo ottimista (ASEAN = 1 accordo ma 11 cluster). Clusterizzare per **accordo (~14)**, e poi:
 - wild cluster bootstrap pensato per pochi cluster;
 - **permutation/randomization inference** che riassegna il *contenuto ambientale* tra gli accordi a timing fisso (lo script `07_triple_diff.R` sezione C lo fa già): è il test più pulito della domanda “è davvero il contenuto ambientale?”.
- **Meccanismo**: riallocazione within-firm (quota green nel paniere verso d , FE fdt) + margine estensivo (entrata di imprese nei green per $d \times t$) + eterogeneità per sub-indice.

3.5 Architettura tecnica (e la fine dei crash)

Qui c'è il guadagno pratico più grande, e merita enfasi:

- **Il risultato identificabile NON richiede le 49 M righe**. La domanda di composizione vive a livello impresa-dest-anno-(tipo prodotto). Un **panel collassato** (o aggregato a $\text{prodotto} \times \text{dest} \times \text{anno}$ per la versione senza imprese) è di ordini di grandezza più piccolo, **gira in memoria senza crash**, e rende la **permutation inference** banale (1000 ripetizioni in minuti, non ore). Le sessioni bruciate su `recursive gc invocation`, `callr`, sottoprocessi, `thread` — sono quasi tutte conseguenza dell'aver tenuto il panel da 15 GB per una domanda che non ne ha bisogno. La dimensione-impresa la tengo **solo** per il modulo riallocazione within-firm (il potenziale headline), dove serve davvero.
- **Pipeline in un solo linguaggio**. Oggi è $R \rightarrow \text{Stata} \rightarrow R$ con percorsi assoluti hardcoded (`C:\Users\edodr\Desktop\...`). Da zero: tutto in R (il `.dta` doganale si legge con `haven/arrow`), `here()` ovunque, zero percorsi-Desktop. Una persona deve poter clonare e rieseguire.

- **Trattamento da tabella, mai da posizione** (vedi §3.2.1): elimina la classe di bug più pericolosa del pregresso.
 - **Tre script, non venti:** `01_build_treatment.R` (da tabella tidy), `02_build_panel.R` (merge + concordanza HS + green/dirty + collasso), `03_estimate.R` (triple-diff + event study – permutation). Il resto è robustezza.
-

4. Cosa terrei e cosa abbandonerei del lavoro esistente

Da tenere (è buon lavoro e va riusato): - Il ridisegno §7 del ROADMAP: la diagnosi e la specifica triple-diff sono giuste. Questo report le conferma. - Gli script `05_dirty_goods.R`, `06_total_depth.R` (con validazione interna), `04_wits_...`, e la sezione C (permutation) di `07_triple_diff.R`: sono già nella direzione giusta. - La **libreria** `pta_functions.R` (caching `.rds`, caricamento colonna-selettivo): ingegneria solida. - Il **wiki**: la base di letteratura è curata e pertinente.

Da abbandonare: - L'effetto-livello come headline → solo diagnostica (ladder). - La **CEM** come strategia identificativa (campione piccolo, bilanciamento debole; strumento sbagliato per questa domanda). - Le **4 strutture di FE come robustezza simmetrica** → una principale + ladder diagnostica. - **PPML su unit value** e la specifica `fpt-only`. - La **depth come conteggio cardinale** → componenti teoriche + binario. - Il **panel da 49 M righe per la stima principale** → collassato (tranne within-firm).

5. Se dovessi ripartire domani: l'ordine concreto

1. **Decisione di meccanismo** (mezza giornata, a tavolino): quali componenti EP hanno un canale commerciale? → definisce il trattamento prima di toccare i dati.
2. **Audit concordanza HS6** (`02_data_hygiene_audit.R`): se i prodotti non sono concordati, *tutto il resto aspetta*. È il single point of failure.
3. **Fondamenta dati**: WITS pref tariffs, dirty (Shapiro), TotalDepth, esclusione HK/MO, tabella accordi tidy.
4. **Panel collassato** impresa-dest-anno-(tipo prodotto) + versione prodotto×dest×anno.
5. **Event study differenziale** green/dirty (il grafico). Questo, da solo, dice se esiste un paper “con risultato” o “precision null”.
6. **Bivio di framing dopo** il punto 5 (non dopo 64 tabelle):
 - effetto di composizione sopravvive → paper JEEM/JIE su composizione + riallocazione within-firm;
 - non sopravvive → contributo “precision null”, posizionato contro Brandi (2020) e Abman-Lundberg-Ruta (2024).

7. **Triple-diff + permutation** come stima principale; within-firm come meccanismo; robustezza in set chiuso.
-

6. La cosa da ricordare

Il progetto non ha un problema di esecuzione — ha un problema di **domanda**. È stato impostato per stimare un effetto che i dati non possono identificare, e gran parte della fatica recente (crash, bootstrap, thread) è il prezzo di aver tenuto un panel enorme al servizio di quella domanda. Spostando la domanda sulla **composizione**, costruendo il **trattamento dal meccanismo**, e lavorando su un **panel collassato con inferenza a livello di accordo**, il progetto diventa più piccolo, più robusto, più pubblicabile — e smette di combattere contro la propria infrastruttura. Il ridisegno §7 ha già imboccato questa strada; quello che aggiungo è di **percorrerla fino in fondo**, anche nell'architettura, non solo nella specifica.