

Le clausole ambientali negli accordi commerciali cinesi

Raccolta commentata di tutte le stime

Edoardo Vitella

Università di Trento & Libera Università di Bolzano

Agosto 2026

Abstract

Questo documento raccoglie **tutte** le stime prodotte per il lavoro sulle clausole ambientali negli accordi commerciali firmati dalla Cina fra il 2000 e il 2015. Ogni tabella è accompagnata da una spiegazione di che cosa è stato stimato, perché, e come vanno letti i numeri. Le tabelle non sono trascritte a mano: nascono direttamente dai file di risultato tramite uno script, così che un aggiornamento delle stime si propaghi automaticamente. Il documento è pensato per essere letto anche da chi non conosce l'econometria applicata al commercio internazionale.

Indice

1	Come leggere questo documento	3
2	Il filo conduttore	5
3	Il contesto: chi sono i partner trattati	6
4	Perché la domanda è stata riformulata	7
4.1	La scala di saturazione	7
5	La specificazione principale	8
5.1	L'idea in una frase	8
5.2	L'equazione	8
5.3	Prima versione: i dati alla massima risoluzione	8
5.4	Seconda versione: gli stessi dati, aggregati	10
6	L'inferenza: quanto possiamo fidarci dei p-value	12
6.1	Il problema	12
6.2	Prima prova: il wild cluster bootstrap	12
6.3	Seconda prova: il test di permutazione	14
6.4	Il quadro completo, con lo stesso metro	15
7	Il confronto è legittimo? Le verifiche dinamiche	16
7.1	Studio dell'evento	16
7.2	La correzione per l'entrata scaglionata	17

8	Robustezza: cambiare il termine di paragone	19
8.1	Gruppi di controllo alternativi	19
8.2	Varianti di campione, controlli e variabile dipendente	20
8.3	Andamenti specifici per destinazione e pre-trend	21
8.4	Il modo in cui si controlla la profondità dell'accordo	23
8.5	Una definizione alternativa di “bene verde”	24
9	Il meccanismo: quali clausole potrebbero mordere	25
10	I margini che le stime principali non vedono	27
10.1	Nascono flussi nuovi?	27
10.2	Una misura continua di inquinamento	28
11	Il risultato dipende da un solo paese?	29
12	Che cosa possiamo davvero escludere	31
13	Che cosa dicono tutte insieme	32

1 Come leggere questo documento

La domanda a cui tutto risponde

Quasi tutti gli accordi commerciali firmati negli ultimi vent'anni contengono clausole ambientali: impegni a proteggere le foreste, a cooperare sul clima, talvolta ad abbassare i dazi sui prodotti “verdi”. La domanda è semplice da enunciare e difficile da rispondere: **queste clausole cambiano davvero il commercio?** Nello specifico: quando la Cina firma un accordo con contenuto ambientale, cambia la *composizione* di ciò che esporta verso quel paese — più prodotti verdi, meno prodotti inquinanti?

I dati

L'universo delle transazioni doganali cinesi in esportazione dal 2000 al 2015: circa 49,2 milioni di righe, ciascuna corrispondente a una combinazione impresa-prodotto-destinazione-anno, per circa 462.000 imprese esportatrici, 5.000 prodotti e 236 destinazioni. A questi si aggiungono due codifiche indipendenti del contenuto ambientale degli accordi (Banca Mondiale e database accademico TREND), una lista OCSE di 246 prodotti ambientali e una classificazione dei settori inquinanti.

Le tre parole che ricorrono in ogni tabella

- **Verde:** il prodotto appartiene alla lista OCSE dei beni ambientali (pannelli solari, turbine, filtri, apparecchi di misurazione ambientale).
- **Sporco:** il prodotto appartiene a un settore tradizionalmente inquinante (carta, chimica di base, raffinazione, siderurgia, metalli non ferrosi).
- **Neutro:** tutto il resto. È il termine di paragone di ogni confronto.

Che cosa significano i coefficienti

Quasi tutte le stime hanno come variabile dipendente il **logaritmo del valore esportato**. Un coefficiente di -0.005 su “Profondità EP $\times$ Sporco” si legge così: *per ogni disposizione ambientale in più contenuta nell'accordo, le esportazioni di prodotti sporchi verso quella destinazione risultano inferiori di circa lo 0,5% rispetto a quelle dei prodotti neutri*. Il confronto è sempre relativo ai prodotti neutri, mai assoluto.

Le quattro colonne che troverete quasi ovunque

Ogni stima principale è stata rifatta quattro volte, incrociando due scelte che potevano influenzare il risultato. Il quadro completo è questo:

Colonna	Campione	Controllo per la profondità dell'accordo
(1)	Senza Hong Kong e Macao	TotalDepth (Banca Mondiale)
(2)	Con Hong Kong e Macao	TotalDepth (Banca Mondiale)
(3)	Senza Hong Kong e Macao	DESTA (fonte esterna)
(4)	Con Hong Kong e Macao	DESTA (fonte esterna)

Perché il primo asse. Hong Kong e Macao sono economie di transito: le merci vi transitano per essere rivendute altrove. Metà del valore esportato verso destinazioni con accordo passa da lì. Includerle o no cambia la natura del campione, quindi si fa in entrambi i modi.

Perché il secondo asse. Gli accordi ricchi di clausole ambientali sono spesso accordi profondi *in tutto*. Se non si tiene conto della profondità complessiva, si rischia di attribuire al contenuto ambientale un merito che appartiene all'accordo nel suo insieme. Si usano quindi due misure alternative della profondità complessiva: quella della Banca Mondiale e quella del database DESTA, costruita da un gruppo di ricerca indipendente (Dur, Baccini & Elsig 2014, sette aree tematiche). Le due hanno una correlazione diversa con la profondità ambientale al netto degli effetti fissi (0,959 la prima, 0,891 la seconda) e questo, come si vedrà, non è un dettaglio.

Convenzioni tipografiche

Nelle tabelle: il coefficiente è il primo numero, l'**errore standard** è fra parentesi tonde, il ***p*-value** fra parentesi quadre. Gli asterischi segnalano la significatività statistica: * per $p < 0.10$, ** per $p < 0.05$, *** per $p < 0.01$. Un *p*-value basso significa che sarebbe improbabile osservare un numero così distante da zero se l'effetto vero fosse nullo.

2 Il filo conduttore

Prima delle tabelle conviene avere in mente il percorso, perché ogni stima risponde a un'obiezione specifica e l'ordine non è casuale.

1. Si parte da una domanda che i dati non possono soddisfare. La domanda naturale sarebbe: *gli accordi con clausole ambientali fanno aumentare le esportazioni?* Purtroppo le clausole entrano in vigore insieme all'accordo e poi non cambiano quasi mai, e gli accordi realmente distinti sono circa quattordici. “Effetto delle clausole ambientali” ed “effetto dell'accordo” sono quindi indistinguibili. La Tabella 2 lo mostra con i dati anziché con un ragionamento.

2. Si riformula la domanda in una a cui si può rispondere. Non “quanto” esporta la Cina, ma “che cosa”: la composizione. Il confronto avviene fra prodotti diversi *dentro la stessa impresa, la stessa destinazione e lo stesso anno*. L'accordo commerciale colpisce tutti i prodotti di quella cella allo stesso modo e quindi si cancella; ciò che resta è il trattamento differenziale dei prodotti verdi e sporchi rispetto ai neutri. Sono le Tabelle 3 e 4.

3. Si prende sul serio il problema dei pochi accordi. Con circa quattordici accordi, i p -value ordinari sono troppo generosi. Ogni risultato viene quindi sottoposto a due prove più severe: il *wild cluster bootstrap* (Tabella 5) e il test di permutazione (Tabella 6). La Tabella 7 riassume tutto con lo stesso metro.

4. Si verifica che il confronto sia legittimo. Se prodotti verdi e neutri divergevano già prima dell'accordo, il confronto non vale. Lo si controlla anno per anno (Tabelle 8 e 9) e con un test formale (Tabella 12).

5. Si cambia il termine di paragone in ogni modo ragionevole. Gruppi di controllo alternativi (Tabella 10), varianti di campione (Tabella 11), modi diversi di controllare la profondità (Tabella 13), una definizione alternativa di “bene verde” (Tabella 14).

6. Si cerca il meccanismo. Se un effetto esistesse, dovrebbe concentrarsi nelle clausole dotate di un vero meccanismo commerciale (Tabella 15).

7. Si guardano i margini che le stime principali non vedono. La nascita di nuovi flussi (Tabella 16) e una misura continua di inquinamento (Tabella 17).

8. Si mette alla prova la fragilità. Il risultato dipende da un singolo paese? (Tabella 18).

9. Si dichiara che cosa si può davvero escludere. Un risultato nullo non significa “effetto assente”: significa “effetto più piccolo di una certa soglia”. La Tabella 19 quantifica quella soglia.

3 Il contesto: chi sono i partner trattati

La Tabella 1 elenca le 25 destinazioni con cui la Cina ha un accordo in vigore nel periodo, l'anno di entrata in vigore e quante disposizioni ambientali contiene l'accordo secondo le due codifiche.

Tre fatti di questa tabella condizionano tutto il resto del lavoro. Primo: le undici destinazioni ASEAN condividono un unico accordo del 2005 e hanno quindi valori identici; gli accordi realmente distinti sono circa quattordici, non venticinque. Secondo: il contenuto ambientale è fissato alla firma e cambia in seguito solo per tre destinazioni. Terzo: Hong Kong e Macao pesano per metà del valore esportato verso destinazioni trattate, il che giustifica l'esistenza del primo asse delle varianti.

Tabella 1: Le destinazioni trattate: quando l'accordo entra in vigore e quanto contenuto ambientale contiene

Destinazione	Codice	Anno di entrata in vigore	Profondità EP massima		
			WB	/	TREND
Bangladesh	103	2002	1	/	1
India	111	2002	1	/	1
Korea Rep.	133	2002	17	/	72
Laos,PDR	119	2002	6	/	4
Sri Lanka	134	2002	1	/	1
HongKong	110	2003	4	/	5
Macau	121	2003	5	/	5
Brunei	105	2005	6	/	4
Cambodia	107	2005	6	/	4
East Timor	144	2005	6	/	4
Indonesia	112	2005	6	/	4
Malaysia	122	2005	6	/	4
Myanmar	106	2005	6	/	4
Philippines	129	2005	6	/	4
Singapore	132	2005	7	/	15
Thailand	136	2005	6	/	4
Vietnam	141	2005	6	/	4
Chile	412	2006	5	/	30
Pakistan	127	2007	3	/	12
New Zealand	609	2008	7	/	53
Peru	434	2010	12	/	47
Costa Rica	415	2011	4	/	50
Iceland	322	2014	6	/	28
Switzerland	331	2014	14	/	53
Australia	601	2015	3	/	24
Totale	25 destinazioni				

Ogni riga è una destinazione con cui la Cina ha un accordo commerciale in vigore fra il 2000 e il 2015.

Profondità EP = quante disposizioni ambientali contiene l'accordo, secondo due codifiche indipendenti: quella della Banca Mondiale (WB) e quella del database accademico TREND.

Le 11 destinazioni ASEAN condividono lo stesso accordo (2005) e quindi gli stessi valori: gli accordi realmente distinti sono circa 14, non 25. È questo il vincolo che governa tutta l'inferenza del lavoro.

Hong Kong e Macao sono economie di transito: metà del valore esportato verso destinazioni trattate passa da lì. Per questo il campione principale le esclude e una variante le reinserisce.

4 Perché la domanda è stata riformulata

4.1 La scala di saturazione

La domanda. Prima di rinunciare all’effetto “di livello” — cioè all’idea di misurare quanto le clausole ambientali facciano crescere le esportazioni in generale — serve una prova che quella strada sia davvero chiusa.

Il modello. Si regredisce il logaritmo delle esportazioni sulla profondità ambientale, aggiungendo via via effetti fissi più stringenti. Ogni riga della Tabella 2 elimina una classe di confronti poco credibili: si parte da un modello che confronta anche imprese e mercati molto diversi fra loro, si arriva a modelli che confrontano solo osservazioni molto simili.

Che cosa dicono i numeri. Il coefficiente è piccolo in tutte le righe e la significatività compare soltanto nella specificazione intermedia, per poi scomparire quando si satura. Questo andamento — significativo solo quando i controlli sono deboli — è la firma tipica della **selezione**: la Cina firma accordi con i partner verso cui già esporta molto e che già stavano crescendo. Non è la firma di un effetto causale, che al contrario dovrebbe resistere man mano che si eliminano le spiegazioni alternative.

La conseguenza. Da qui la scelta di abbandonare la domanda sul livello e passare alla domanda sulla composizione, che i dati possono invece identificare.

Tabella 2: Perché l’effetto *di livello* non è stimabile: la scala di saturazione

Fixed Effects	WB EP Depth		TREND EP Count	
	(1) Baseline	(2) Controls	(3) Baseline	(4) Controls
$f_{pd} + t$	0.00311 (0.00251)	0.00354 (0.00260)	0.00040 (0.00047)	0.00046 (0.00048)
$f_{pt} + p_{d}$	0.00463* (0.00270)	0.00476* (0.00274)	0.00101** (0.00051)	0.00105** (0.00052)
$f_{pt} + f_{pd}$	0.00010 (0.00326)	0.00010 (0.00329)	0.00016 (0.00061)	0.00016 (0.00060)
$f_{pd} + p_{t}$	0.00087 (0.00225)	0.00103 (0.00221)	0.00028 (0.00044)	0.00030 (0.00044)
Notes: SEs clustered at destination (<code>country_code</code>). N varies across specs. * $p < 0.10$, ** $p < 0.05$, *** $p < 0.01$				

Variabile dipendente: logaritmo del valore esportato. Ogni riga aggiunge effetti fissi più stringenti, cioè elimina confronti sempre meno credibili.

Notazione: f = impresa, p = prodotto, d = destinazione, t = anno.

Il coefficiente è piccolo ovunque e la significatività compare solo nella specificazione intermedia, per poi sparire quando si satura. È il segno tipico della **selezione**: la Cina firma accordi con i partner verso cui già esporta molto. Da qui la scelta di abbandonare l’effetto di livello e passare alla composizione.

Errore standard fra parentesi, raggruppato per destinazione.

5 La specificazione principale

5.1 L'idea in una frase

Si confrontano prodotti verdi, sporchi e neutri *all'interno della stessa cella impresa-destinazione-anno*. Tutto ciò che riguarda quell'impresa su quel mercato in quell'anno — l'accordo commerciale, i tagli tariffari, la burocrazia doganale, uno shock di domanda — colpisce i suoi prodotti allo stesso modo e viene quindi eliminato dal confronto. Ciò che resta è il trattamento *differenziale* dei prodotti verdi e sporchi. Se le clausole ambientali fanno qualcosa, deve vedersi qui.

5.2 L'equazione

$$\ln x_{fpdt} = \beta_1 EP_{dt} \times g_p + \beta_2 EP_{dt} \times b_p + \gamma_1 TD_{dt} \times g_p + \gamma_2 TD_{dt} \times b_p + \theta_{fpd} + \theta_{fdt} + \theta_{pt} + \varepsilon_{fpdt}$$

dove f è l'impresa, p il prodotto, d la destinazione, t l'anno; g_p e b_p indicano prodotto verde e prodotto sporco; EP_{dt} è la profondità ambientale dell'accordo e TD_{dt} la profondità complessiva. I tre termini θ sono gli effetti fissi. **I coefficienti di interesse sono β_1 e β_2** : gli altri servono a impedire che il contenuto ambientale prenda il merito della profondità generale dell'accordo.

5.3 Prima versione: i dati alla massima risoluzione

Che cosa dicono i numeri (Tabella 3). Sul **marginale verde** il coefficiente è praticamente nullo in tutte e quattro le colonne, fra -0.0009 e -0.0023 , e non è mai lontanamente significativo (p fra 0,57 e 0,80). Sul **marginale sporco** il coefficiente è sistematicamente negativo, fra -0.0041 e -0.0057 , con p -value fra 0,034 e 0,094: sarebbe una riduzione di circa mezzo punto percentuale delle esportazioni sporche per ogni disposizione ambientale in più. Il modello spiega circa l'87% della variabilità (R^2), valore alto dovuto quasi interamente agli effetti fissi.

Un avvertimento importante sulla lettura: le righe della *profondità accordo* non sono confrontabili fra le colonne (1)–(2) e (3)–(4), perché le due misure sono su scale diverse. Le righe della *profondità ambientale*, che sono quelle che interessano, usano invece la stessa misura ovunque.

Tabella 3: Specificazione principale — dati a livello di singola transazione (*full panel*)

	(1)	(2)	(3)	(4)
<i>Pannello A — profondità ambientale misurata dalla Banca Mondiale</i>				
Profondità EP (WB) × Verde	-0.00226 (0.00393) [0.566]	-0.00090 (0.00360) [0.804]	-0.00185 (0.00366) [0.613]	-0.00196 (0.00347) [0.572]
Profondità EP (WB) × Sporco	-0.00435* (0.00223) [0.052]	-0.00409* (0.00243) [0.094]	-0.00559** (0.00269) [0.039]	-0.00574** (0.00269) [0.034]
Profondità accordo × Verde	0.00006 (0.00010) [0.560]	0.00001 (0.00011) [0.938]	0.00239 (0.00628) [0.704]	0.00321 (0.00570) [0.574]
Profondità accordo × Sporco	0.00019* (0.00010) [0.053]	0.00019** (0.00010) [0.044]	0.01394** (0.00696) [0.046]	0.01498** (0.00725) [0.040]
<i>Pannello B — profondità ambientale misurata da TREND</i>				
Conteggio EP (TREND) × Verde	-0.00010 (0.00100) [0.924]	-0.00011 (0.00100) [0.913]	-0.00012 (0.00099) [0.904]	-0.00039 (0.00093) [0.675]
Conteggio EP (TREND) × Sporco	-0.00089 (0.00062) [0.153]	-0.00101 (0.00063) [0.112]	-0.00140** (0.00071) [0.048]	-0.00140* (0.00072) [0.052]
Profondità accordo × Verde	-0.00000 (0.00016) [0.982]	-0.00001 (0.00016) [0.966]	0.00005 (0.00937) [0.996]	0.00271 (0.00758) [0.721]
Profondità accordo × Sporco	0.00017 (0.00013) [0.191]	0.00020 (0.00013) [0.129]	0.01500** (0.00756) [0.049]	0.01519* (0.00780) [0.053]
Osservazioni	21,519,511	23,560,110	21,517,666	23,381,204
R^2	0.8734	0.8706	0.8734	0.8710
Effetti fissi	impresa×prod.×dest.; impresa×dest.×anno; prod.×anno			
Raggruppamento errori	destinazione			

Colonne: (1) Escl. HK/Macao, controllo TotalDepth (baseline); (2) Incl. HK/Macao, controllo TotalDepth; (3) Escl. HK/Macao, controllo DESTA; (4) Incl. HK/Macao, controllo DESTA.

Variabile dipendente: logaritmo del valore esportato dall'impresa f del prodotto p verso la destinazione d nell'anno t .

L'effetto fisso $\text{impresa} \times \text{destinazione} \times \text{anno}$ assorbe *tutto* ciò che accade a quell'impresa su quel mercato in quell'anno — compreso l'accordo commerciale stesso, i tagli tariffari e gli shock di domanda. Resta identificato solo il confronto fra prodotti verdi, sporchi e neutri all'interno della stessa cella.

I coefficienti sono in punti logaritmici per unità di profondità: -0.005 significa circa -0.5% di esportazioni per ogni disposizione ambientale in più, rispetto ai prodotti neutri.

Attenzione alle scale. Le righe *Profondità accordo* non sono confrontabili fra le colonne (1)–(2) e (3)–(4): nelle prime due il controllo è un conteggio di disposizioni della Banca Mondiale, nelle altre due è l'indice DESTA, costruito su una scala del tutto diversa. Le righe della profondità *ambientale*, che sono quelle di interesse, usano invece la stessa misura in tutte e quattro le colonne e restano quindi pienamente confrontabili.

Stima con `reghdfe` (Stata), rimozione iterativa dei singleton.

Errore standard fra parentesi tonde, p -value fra parentesi quadre. * $p < 0.10$, ** $p < 0.05$, *** $p < 0.01$.

5.4 Seconda versione: gli stessi dati, aggregati

Perché rifare tutto su dati aggregati. Due ragioni. La prima è di verifica: se il risultato dipendesse dal livello di dettaglio, sarebbe un campanello d'allarme. La seconda è pratica: molte procedure — il bootstrap, le mille ripetizioni del test di permutazione — sono impossibili su 21 milioni di osservazioni e diventano fattibili su 3,7 milioni di celle.

Che cosa cambia. L'unità di osservazione diventa la cella prodotto–destinazione–anno, e ogni cella viene pesata per il numero di osservazioni d'impresa che contiene. Gli effetti fissi si adattano di conseguenza.

Che cosa dicono i numeri (Tabella 4). Il margine verde resta nullo, come nel *full panel*. Il margine sporco ha coefficienti più grandi in valore assoluto, fra -0.0082 e -0.0189 , con p -value ordinari molto bassi. **Ma questi p -value ordinari sono proprio quelli di cui non ci si può fidare con così pochi accordi:** la sezione successiva li sottopone a prove più severe, e il quadro cambia parecchio.

Una differenza da tenere a mente. Nel *full panel* ogni osservazione pesa uno; qui le celle grandi pesano di più. Verificato algebricamente sui dati reali: i minimi quadrati pesati con n_i come pesi producono coefficienti identici al micro (differenza massima 7×10^{-16}). La divergenza fra pannello collassato e *full panel* non viene quindi dalla ponderazione ma dalla struttura degli effetti fissi: il collassato usa $pd+dt+pt$, il *full panel* $fpd+fdt+pt$. La colonna (4) differisce dalle altre perché con Hong Kong e Macao inclusi gli effetti fissi fdt catturano dinamiche impresa-specifiche molto diverse da quelle del gruppo di controllo.

Tabella 4: Specificazione principale — dati aggregati per prodotto, destinazione e anno (*pannello collasato*)

	(1)	(2)	(3)	(4)
<i>Pannello A — profondità ambientale misurata dalla Banca Mondiale</i>				
Profondità EP (WB) × Verde	-0.00457 (0.00696) [0.512]	0.00173 (0.00907) [0.849]	-0.00433 (0.00435) [0.320]	-0.00675 (0.00475) [0.157]
Profondità EP (WB) × Sporco	-0.01187*** (0.00295) [<0.001]	-0.01887*** (0.00610) [0.002]	-0.01134*** (0.00223) [<0.001]	-0.00820* (0.00425) [0.055]
Profondità accordo × Verde	-0.00005 (0.00024) [0.832]	-0.00028 (0.00033) [0.396]	-0.00336 (0.00863) [0.697]	0.00527 (0.00975) [0.590]
Profondità accordo × Sporco	0.00037** (0.00018) [0.039]	0.00067** (0.00030) [0.027]	0.01927*** (0.00541) [<0.001]	0.00886 (0.01113) [0.427]
<i>Pannello B — profondità ambientale misurata da TREND</i>				
Conteggio EP (TREND) × Verde	0.00181 (0.00182) [0.320]	0.00178 (0.00185) [0.337]	0.00161 (0.00203) [0.428]	0.00017 (0.00199) [0.931]
Conteggio EP (TREND) × Sporco	0.00035 (0.00160) [0.826]	-0.00001 (0.00154) [0.995]	-0.00025 (0.00138) [0.858]	0.00084 (0.00149) [0.575]
Profondità accordo × Verde	-0.00047* (0.00026) [0.066]	-0.00047* (0.00025) [0.060]	-0.02303 (0.01437) [0.110]	-0.00771 (0.01556) [0.621]
Profondità accordo × Sporco	-0.00013 (0.00030) [0.674]	-0.00004 (0.00031) [0.898]	-0.00006 (0.01291) [0.996]	-0.01198 (0.01408) [0.396]
Celle	3,681,023	3,769,187	3,677,333	3,759,733
Effetti fissi	prod.×dest.; dest.×anno; prod.×anno			
Ponderazione	numero di osservazioni impresa nella cella			
Raggruppamento errori	destinazione			

Colonne: (1) Escl. HK/Macao, controllo TotalDepth (baseline); (2) Incl. HK/Macao, controllo TotalDepth; (3) Escl. HK/Macao, controllo DESTA; (4) Incl. HK/Macao, controllo DESTA.

Stessa logica della Tabella 3, ma l'unità di osservazione è la cella prodotto–destinazione–anno anziché la singola transazione d'impresa. Serve a verificare che il risultato non dipenda dal livello di aggregazione e rende eseguibili stime altrimenti troppo pesanti.

Il R^2 non è stato esportato per questa specificazione (i CSV non lo contengono).

Ogni cella è pesata per il numero di osservazioni impresa che contiene: le celle più grandi contano di più. È la differenza chiave rispetto al *full panel*, dove ogni osservazione pesa uno.

Errore standard fra parentesi tonde, p -value fra parentesi quadre. * $p < 0.10$, ** $p < 0.05$, *** $p < 0.01$.

6 L'inferenza: quanto possiamo fidarci dei p -value

6.1 Il problema

I p -value ordinari si basano su un'approssimazione che funziona quando i gruppi entro cui si raggruppano gli errori sono numerosi. Qui i gruppi trattati sono ventitré e gli accordi realmente distinti circa quattordici. In questa situazione l'approssimazione dichiara significativo ciò che non lo è, e lo fa in modo tanto più marcato quanto più i gruppi sono diversi fra loro per dimensione — cosa che qui accade in misura notevole. Per questo ogni risultato viene sottoposto a due prove aggiuntive.

6.2 Prima prova: il wild cluster bootstrap

Come funziona, in parole semplici. Invece di fidarsi di una formula, si ricostruisce la distribuzione del coefficiente per forza bruta: si rimescolano i dati 9.999 volte secondo uno schema che rispetta la struttura a gruppi, si ristima ogni volta, e si guarda dove cade il coefficiente vero rispetto a quella distribuzione.

Nota metodologica. Il *bootstrap* viene applicato al pannello collassato (celle *pdt*), non al *full panel*. La validità dell'inferenza collassata rispetto al micro è garantita dal teorema di Frisch-Waugh: i coefficienti sul pannello collassato con pesi n_i coincidono algebricamente con quelli del micro a parità di struttura degli effetti fissi. Un elemento tecnico rilevante: l'effetto fisso *pt* non è annidato nel cluster destinazione, quindi il *demeaning* avviene prima del *bootstrap* — comportamento standard di *feols* in questo contesto.

Che cosa dicono i numeri (Tabella 5). Sul margine verde nulla cambia: i p -value restano altissimi ovunque. Sul margine sporco il quadro si articola. Sul *full panel* il p -value bootstrap è 0,185 e 0,176 nelle colonne con il controllo della Banca Mondiale, ma scende a 0,049 e 0,035 nelle colonne con il controllo DESTA. Sul pannello collassato si va da 0,005 a 0,198 a seconda della variante.

Il confronto che vale la pena fare. Nel pannello collassato baseline il p -value ordinario del margine sporco è inferiore a 0,001, quello bootstrap è 0,070. Non è un dettaglio tecnico: è la differenza fra “fortemente significativo” e “appena al di sopra della soglia convenzionale”.

Tabella 5: Inferenza robusta: *wild cluster bootstrap* con 9.999 ripetizioni

	(1)	(2)	(3)	(4)
<i>Pannello A — pannello collassato (indice WB)</i>				
Profondità EP × Verde: coefficiente	-0.00457	0.00173	-0.00433	-0.00675
<i>p</i> -value bootstrap	0.649	0.825	0.546	0.484
Profondità EP × Sporco: coefficiente	-0.01187	-0.01887	-0.01134	-0.00820
<i>p</i> -value bootstrap	0.072	0.005	0.047	0.195
<i>Pannello B — pannello collassato (indice TREND)</i>				
Conteggio EP × Verde: coefficiente	0.00181	0.00178	0.00161	0.00017
<i>p</i> -value bootstrap	0.390	0.414	0.508	0.949
Conteggio EP × Sporco: coefficiente	0.00035	-0.00001	-0.00025	0.00084
<i>p</i> -value bootstrap	0.857	0.995	0.905	0.635
<i>Pannello C — full panel (indice WB)</i>				
Profondità EP × Verde: coefficiente	-0.00226	-0.00090	-0.00185	-0.00196
<i>p</i> -value bootstrap	0.686	0.833	0.673	0.611
Profondità EP × Sporco: coefficiente	-0.00435	-0.00409	-0.00559	-0.00574
<i>p</i> -value bootstrap	0.185	0.176	0.049	0.035
<i>Pannello D — full panel (indice TREND)</i>				
Conteggio EP × Verde: coefficiente	-0.00010	-0.00011	-0.00012	-0.00039
<i>p</i> -value bootstrap	0.931	0.919	0.920	0.703
Conteggio EP × Sporco: coefficiente	-0.00089	-0.00101	-0.00140	-0.00140
<i>p</i> -value bootstrap	0.177	0.142	0.069	0.082

Colonne: (1) Escl. HK/Macao, controllo TotalDepth (baseline); (2) Incl. HK/Macao, controllo TotalDepth; (3) Escl. HK/Macao, controllo DESTA; (4) Incl. HK/Macao, controllo DESTA.

A cosa serve. I *p*-value ordinari sono affidabili quando i gruppi su cui si raggruppano gli errori sono molti. Qui i gruppi trattati sono 23 e gli accordi realmente distinti circa 14: in questa situazione i *p*-value ordinari tendono a dichiarare significativo ciò che non lo è. Il *wild cluster bootstrap* ricostruisce la distribuzione del coefficiente rimescolando i dati 9.999 volte e restituisce un *p*-value molto più prudente.

Il confronto con la Tabella 4 è istruttivo: dove il *p*-value ordinario è < 0.001 , quello bootstrap può salire sopra 0.05.

Pannelli C e D calcolati con `boottest` in Stata su dati residualizzati (Frisch–Waugh), perché il comando non regge più di un insieme di effetti fissi assorbiti.

6.3 Seconda prova: il test di permutazione

Come funziona. È la prova più intuitiva e la più severa. Si prende il profilo di contenuto ambientale di ciascun accordo — quanto è profondo, in quali anni — e lo si riassegna a caso fra le destinazioni che hanno già un accordo. Poi si ristima. Mille volte. Se il coefficiente vero non spicca fra i mille coefficienti finti, significa che qualunque etichettatura casuale di quei paesi avrebbe prodotto lo stesso numero, e quindi che il risultato non dipende dal contenuto ambientale.

Che cosa dicono i numeri (Tabella 6). Sul margine verde i p -value vanno da 0,148 a 0,773: il coefficiente osservato è del tutto ordinario fra i mille finti. Sul margine sporco si ottiene 0,023 nella variante baseline, 0,003 e 0,036 in due delle altre, ma 0,489 nella quarta. Quest’ultima è la stessa colonna che si comporta in modo anomalo anche nelle altre prove.

Tabella 6: Test di permutazione: 1.000 riassegnazioni casuali del contenuto ambientale

	(1)	(2)	(3)	(4)
<i>Pannello A — indice WB</i>				
Profondità EP × Verde: coefficiente osservato	-0.00457	0.00173	-0.00433	-0.00675
p -value di permutazione	0.597	0.898	0.481	0.457
permutazioni valide	1,000	1,000	1,000	1,000
Profondità EP × Sporco: coefficiente osservato	-0.01187	-0.01887	-0.01134	-0.00820
p -value di permutazione	0.278	0.137	0.140	0.384
permutazioni valide	1,000	1,000	1,000	1,000
<i>Pannello B — indice TREND</i>				
Profondità EP × Verde: coefficiente osservato	0.00181	0.00178	0.00161	0.00017
p -value di permutazione	0.160	0.481	0.324	0.935
permutazioni valide	1,000	1,000	1,000	1,000
Profondità EP × Sporco: coefficiente osservato	0.00035	-0.00001	-0.00025	0.00084
p -value di permutazione	0.817	0.997	0.902	0.791
permutazioni valide	1,000	1,000	1,000	1,000

Colonne: (1) Escl. HK/Macao, controllo TotalDepth (baseline); (2) Incl. HK/Macao, controllo TotalDepth; (3) Escl. HK/Macao, controllo DESTA; (4) Incl. HK/Macao, controllo DESTA.

Come funziona. Si prende il profilo di contenuto ambientale di ciascun accordo (quanto è profondo e in quali anni) e lo si riassegna a caso fra le destinazioni già trattate, 1.000 volte. Ogni volta si ristima il modello. Il p -value è la quota di riassegnazioni casuali che produce un coefficiente più grande in valore assoluto di quello vero.

Come si legge. Un p -value alto significa: “lo stesso numero si sarebbe ottenuto etichettando a caso questi paesi”, cioè il risultato non dipende dal contenuto ambientale. Un p -value basso significa che il numero osservato spicca fra i mille finti.

È il test più severo dei tre usati nel lavoro, perché non assume nulla sulla distribuzione degli errori.

Replica in Stata della colonna baseline (56b_permutation_treatedonly.do, stesso disegno, 1.000 estrazioni): coefficienti osservati identici fino alla dodicesima cifra; p -value 0,597 (WB verde), 0,278 (WB sporco), 0,160 (TREND verde), 0,817 (TREND sporco). Gli scarti di qualche punto rispetto a R sono attesi: i profili ambientali realmente distinti sono circa nove (gli undici paesi ASEAN condividono lo stesso accordo), quindi la distribuzione di permutazione è granulare e il p non è riproducibile all’ultima cifra fra implementazioni diverse. Il paper cita i valori Stata.

6.4 Il quadro completo, con lo stesso metro

La Tabella 7 raccoglie in un'unica vista il coefficiente sui prodotti sporchi nelle quattro varianti e nelle due unità di analisi, **usando ovunque il p -value bootstrap**. È una precisazione necessaria: presentare per alcune colonne il p -value ordinario e per altre quello bootstrap darebbe un'impressione distorta, perché i due possono differire di ordini di grandezza.

Che cosa emerge. Sul *full panel* — l'unità su cui poggiano le stime principali — il risultato dipende in modo netto da quale controllo di profondità si adotta: con il controllo della Banca Mondiale il p -value resta sopra 0,17, con il controllo DESTA scende sotto 0,05. La spiegazione più immediata è meccanica: i due controlli hanno correlazione diversa con la profondità ambientale al netto degli effetti fissi (0,959 TotalDepth, 0,891 DESTA), quindi con il primo resta meno variazione indipendente e l'errore standard è più grande. È però una lettura incompleta. DESTA copre solo sette aree tematiche contro diciassette di TotalDepth: un controllo più grossolano è meno collineare anche perché misura il confondente in modo meno preciso, e un confondente misurato male lascia parte di sé nel coefficiente EP. In quel caso la significatività che compare nelle colonne (3)–(4) può essere confondimento residuo, non precisione recuperata. **Entrambe le letture sono plausibili** e questo è il bivio da dichiarare, non da nascondere: la specificazione di riferimento adotta TotalDepth per ragioni di completezza, ma chi sceglie DESTA ottiene un risultato più “robusto” la cui origine non è accertata.

Come questo va detto nel lavoro. Il margine sporco è negativo nella grande maggioranza delle specificazioni, ma *non in tutte*: sotto il gruppo di controllo più stretto (prodotti della stessa famiglia merceologica, prima riga di Tabella 10) il segno si inverte. La formulazione difendibile non è “sistematicamente negativo”, ma: l'evidenza è *suggestiva e coerente in quasi tutte le varianti*, con significatività statistica che dipende dal controllo adottato — scelta che va motivata in anticipo.

Tabella 7: Sintesi: il coefficiente sui prodotti sporchi nelle quattro varianti, con lo stesso metodo di inferenza

	(1)	(2)	(3)	(4)
Pannello collassato: coefficiente	-0.01187	-0.01887	-0.01134	-0.00820
p -value bootstrap	0.072	0.005	0.047	0.195
<i>Full panel</i> : coefficiente	-0.00435	-0.00409	-0.00559	-0.00574
p -value bootstrap	0.185	0.176	0.049	0.035

Colonne: (1) Escl. HK/Macao, controllo TotalDepth (baseline); (2) Incl. HK/Macao, controllo TotalDepth; (3) Escl. HK/Macao, controllo DESTA; (4) Incl. HK/Macao, controllo DESTA.

Coefficiente dell'interazione fra profondità ambientale (indice WB) e prodotti sporchi. È l'unico coefficiente del lavoro che si muove: quello sui prodotti verdi è nullo ovunque.

Tutti i p -value in questa tabella vengono dal *wild cluster bootstrap*, così le otto celle sono confrontabili fra loro. È una precisazione necessaria: altrove nel progetto le colonne (1) e (2) erano state riassunte con il p -value ordinario, che è molto più basso e non è paragonabile.

Come si legge. Sul *full panel* il risultato dipende da quale controllo di profondità si usa: con il controllo della Banca Mondiale il p -value resta sopra 0.17, con il controllo DESTA scende sotto 0.05. I due controlli hanno correlazione diversa con la profondità ambientale al netto degli effetti fissi (0.959 il primo, 0.891 il secondo): più un controllo è sovrapposto alla variabile di interesse, meno variazione indipendente resta e più grande diventa l'errore standard.

7 Il confronto è legittimo? Le verifiche dinamiche

7.1 Studio dell'evento

L'assunzione da verificare. Tutto il disegno poggia su un'ipotesi: che, in assenza di clausole ambientali, prodotti verdi e neutri avrebbero continuato ad andare allo stesso modo. Non è dimostrabile — riguarda un mondo che non osserviamo — ma è falsificabile: se i due gruppi divergevano già *prima* dell'accordo, l'ipotesi è insostenibile.

Il modello. Si sostituisce la variabile di trattamento con una serie di indicatori “anni dall'entrata in vigore”, ciascuno interagito con verde e sporco. L'anno -1 fa da riferimento: tutti gli altri coefficienti misurano la distanza da quell'anno.

Che cosa dicono i numeri (Tabella 8). Nei periodi precedenti l'entrata i coefficienti sono vicini a zero e non significativi, sia per i verdi sia per gli sporchi: la verifica è superata. All'anno zero e successivi non compare alcun salto. Per i verdi si intravede una deriva negativa negli anni più lontani, ma quei coefficienti sono stimati su pochi accordi ed hanno errori standard ampi.

Tabella 8: Studio dell'evento: andamento anno per anno attorno all'entrata in vigore dell'accordo

Anni dall' entrata	Prodotti verdi vs neutri		Prodotti sporchi vs neutri	
	Coefficiente	Errore std.	Coefficiente	Errore std.
-6	-0.0439	(0.0446)	0.0270	(0.0432)
-5	-0.0053	(0.0382)	-0.0168	(0.0253)
-4	0.0171	(0.0265)	0.0360	(0.0269)
-3	-0.0081	(0.0197)	0.0020	(0.0283)
-2	0.0059	(0.0193)	0.0203	(0.0394)
+0	0.0068	(0.0142)	0.0274	(0.0268)
+1	0.0105	(0.0204)	0.0167	(0.0284)
+2	-0.0196	(0.0236)	0.0209	(0.0327)
+3	-0.0383	(0.0265)	0.0199	(0.0345)
+4	-0.0394	(0.0333)	0.0210	(0.0348)
+5	-0.0843	(0.0336)	-0.0315	(0.0426)
-1	<i>anno di riferimento (normalizzato a zero)</i>			

Variante baseline (escl. HK/Macao, controllo TotalDepth), pannello collassato, effetti fissi prod. $\times$ dest., dest. $\times$ anno, prod. $\times$ anno; errori raggruppati per destinazione.

A cosa serve. Prima dell'entrata in vigore l'accordo non può avere effetto: se i coefficienti *prima* dell'anno zero fossero già diversi da zero, vorrebbe dire che prodotti verdi e neutri stavano già divergendo per altri motivi, e il confronto non sarebbe credibile.

Come si legge. Valori vicini a zero e non significativi prima dell'entrata (righe negative) sostengono il disegno; l'assenza di un salto all'anno zero e dopo è il risultato.

L'anno -1 è il termine di paragone: tutti gli altri coefficienti misurano la distanza da quell'anno.

7.2 La correzione per l'entrata scaglionata

Il problema tecnico. Quando gli accordi entrano in vigore in anni diversi — qui dal 2002 al 2015 — lo stimatore tradizionale finisce per usare come termine di paragone anche unità già trattate, e questo può distorcere il risultato. Sun e Abraham (2021) hanno proposto una correzione che calcola l'effetto separatamente per ciascun gruppo di ingresso e poi lo aggrega correttamente.

L'adattamento necessario. Il metodo si applica a un confronto scaglionato ordinario, non a una tripla differenza. Si costruisce quindi una variabile dipendente che è già un *divario*: media dei prodotti verdi meno media dei neutri nella stessa destinazione e anno. A quel punto il metodo si applica direttamente.

Un dettaglio che cambia la lettura: gli errori standard. Le quote con cui si aggregano i gruppi di ingresso non sono note, sono *stimate* sui dati, e Sun e Abraham prescrivono di tenerne conto nel calcolo della precisione. Il pacchetto R usato in origine (`fixest::sunab`) le tratta invece come pesi fissi. I coefficienti sono identici fino alla quindicesima cifra, la precisione no: dove un solo gruppo di ingresso identifica il periodo i due errori standard coincidono esattamente (non c'è nulla da stimare), dove i gruppi sono molti e discordi quello corretto è fino a 3-4 volte più grande. Poiché i periodi *anteriori* all'entrata sono proprio quelli in cui i gruppi divergono di più, trattare le quote come note fabbrica pre-trend apparenti a partire da quella divergenza. Questa tabella riporta gli errori standard corretti, calcolati in Stata con `eventstudyinteract`.

Che cosa dicono i numeri (Tabella 9). Nessun salto sistematico attorno all'entrata in vigore, e — con gli errori standard corretti — nessun coefficiente distinguibile da zero nella finestra mostrata, né prima né dopo. Il caso più istruttivo è il divario sporco sei anni *prima* dell'entrata: con i pesi trattati come noti risultava +0,047 con $p = 0,001$, cioè un pre-trend allarmante; con la varianza corretta lo stesso coefficiente ha $p = 0,34$. Guardando i singoli gruppi si capisce perché: il Cile devia di -0,49 e il Perù di -0,33, la Nuova Zelanda di +0,14 e l'Australia di +0,10. Non c'è uno spostamento comune, ci sono oscillazioni di segno opposto mediate in un numero solo — ed è esattamente quello che la varianza corretta segnala.

Tabella 9: Stimatore di Sun e Abraham applicato al divario di composizione

Anni dall' entrata	Divario verdi – neutri		Divario sporchi – neutri	
	Coefficiente	<i>p</i> -value	Coefficiente	<i>p</i> -value
-10	-0.0500	0.419	-0.0356	0.598
-9	-0.0128	0.881	0.0641	0.424
-8	-0.0001	0.999	-0.0478	0.436
-7	-0.0392	0.422	-0.0186	0.561
-6	0.0027	0.959	0.0466	0.335
-5	0.0022	0.961	-0.0447	0.378
-4	0.0345	0.359	-0.0210	0.538
-3	0.0021	0.938	-0.0451	0.189
-2	0.0034	0.861	-0.0080	0.832
+0	0.0116	0.504	0.0579	0.107
+1	0.0191	0.470	0.0661	0.192
+2	-0.0049	0.881	0.0765	0.241
+3	-0.0244	0.501	0.0921	0.156
+4	-0.0187	0.711	0.0906	0.181
+5	-0.0233	0.661	0.1153	0.117
+6	0.0027	0.959	0.1264	0.165
+7	-0.0320	0.541	0.1083	0.223
+8	-0.0779	0.181	0.0983	0.235
ATT aggregato	-0.0421	0.269	0.0729	0.276

Variante baseline. Finestra mostrata: da -10 a $+8$ anni; il file completo copre un intervallo più ampio.

Fonte: **Stata** (`eventstudyinteract`, `60_sunab_collapsed.do`). I coefficienti coincidono con quelli di R (`fixest::sunab`) fino alla quindicesima cifra; gli errori standard no. Quelli riportati qui includono l'incertezza con cui sono *stimate* le quote di ciascun gruppo di ingresso, come prescrive Sun e Abraham (2021); R le tratta invece come pesi noti e sottostima la variabilità dei coefficienti lontani dall'entrata. Verifica interna: dove un solo gruppo identifica il periodo i due errori standard coincidono esattamente; dove i gruppi sono molti e discordi quello corretto è fino a 3-4 volte più grande.

L'ATT aggregato è la media dei periodi successivi all'entrata, pesata per la dimensione delle celle.

Perché serve. Quando gli accordi entrano in vigore in anni diversi (qui: dal 2002 al 2015), lo stimatore tradizionale può confondere l'effetto vero con il confronto fra chi è stato trattato prima e chi dopo. Sun e Abraham (2021) propongono una correzione che calcola l'effetto separatamente per ogni gruppo di ingresso e poi lo aggrega.

Come si legge. La variabile dipendente qui non è l'export ma il *divario*: media dei prodotti verdi meno media dei neutri, nella stessa destinazione e anno. Così il disegno diventa un confronto scaglionato ordinario, a cui il metodo si applica direttamente.

Un coefficiente significativo *prima* dell'anno zero è un segnale di allarme, non un risultato: va discusso apertamente.

* $p < 0.10$, ** $p < 0.05$, *** $p < 0.01$.

8 Robustezza: cambiare il termine di paragone

8.1 Gruppi di controllo alternativi

L’obiezione. Nella specificazione principale i prodotti verdi sono confrontati con tutti gli altri, compresi prodotti che con i verdi non hanno nulla in comune. Se il risultato dipendesse da questa scelta, non sarebbe affidabile.

Le tre restrizioni (Tabella 10). Si tengono solo i non-verdi della stessa famiglia merceologica; oppure solo i partner che hanno già un accordo, confrontando quelli con contenuto ambientale sopra e sotto la mediana — così sparisce del tutto il confronto fra chi ha un accordo e chi non ce l’ha, e con esso il sospetto che la Cina scelga i partner per motivi non osservati; oppure solo destinazioni appaiate per reddito, crescita e dazi.

Che cosa dicono i numeri. Il coefficiente sul margine verde resta piccolo e non significativo in tutte e tre le restrizioni. È il punto: un artefatto del termine di paragone si muoverebbe quando il termine di paragone si muove. I p -value di questa tabella sono asintotici; il *bootstrap* di Tabella 5 è il riferimento per l’inferenza.

Tre caveat dichiarati. (i) *Profondi vs superficiali*: il gruppo “superficiali” comprende circa 8 cluster trattati, rendendo il *wild cluster bootstrap* ancora meno affidabile di quanto non sia già nel campione completo. (ii) *Destinazioni appaiate (CEM)*: il bilanciamento ottenuto è debole — l’ L_1 migliora da 0,788 a 0,652 ma $\log_gdppc_2000$ peggiora oltre soglia (SMD $-0,108$); va interpretata come analisi esplorativa, non come identificazione pulita. (iii) *Stessa famiglia merceologica*: con prodotti della stessa HS4 come controllo, il coefficiente sporco si inverte di segno; come documentato da Eckel et al. (2023), la restrizione HS4 può catturare spillover intrafamiglia, per cui questa variante non è interpretabile da sola.

Tabella 10: Gruppi di controllo alternativi: il risultato cambia se cambia il termine di paragone?

Gruppo di controllo	Indice WB		Indice TREND	
	× Verde	× Sporco	× Verde	× Sporco
Solo prodotti della stessa famiglia merceologica	-0.00090 (0.00505) [0.858]	0.00655 (0.00904) [0.469]	0.00047 (0.00115) [0.680]	0.00242 (0.00657) [0.714]
<i>osservazioni: 3,772,855</i>				
Solo partner con accordo: profondi vs superficiali	-0.00222 (0.00351) [0.534]	-0.00344 (0.00289) [0.246]	-0.00036 (0.00100) [0.721]	-0.00061 (0.00101) [0.549]
<i>osservazioni: 5,262,293</i>				
Solo destinazioni appaiate per caratteristiche	-0.00228 (0.00371) [0.543]	-0.00417* (0.00238) [0.085]	-0.00059 (0.00109) [0.590]	-0.00115 (0.00074) [0.129]
<i>osservazioni: 13,728,510</i>				

Variante baseline, dati a livello di transazione, effetti fissi come nella Tabella 3; errori raggruppati per destinazione.

A cosa serve. Nella specificazione principale i prodotti verdi sono confrontati con *tutti* gli altri. Qui il paragone viene ristretto in tre modi diversi e sempre più severi. Se il risultato dipendesse dalla scelta del termine di paragone, cambierebbe passando da una riga all’altra.

Stessa famiglia merceologica: i non-verdi ammessi come confronto sono solo quelli che condividono le prime quattro cifre del codice doganale con un prodotto verde.

Profondi vs superficiali: si tengono solo i partner che hanno già un accordo, e si confrontano quelli con contenuto ambientale sopra la mediana con quelli sotto. Così sparisce del tutto il confronto fra chi ha un accordo e chi non ce l’ha.

Destinazioni appaiate: si tengono solo i paesi di controllo simili ai trattati per reddito, crescita e livello dei dazi nel 2000 (*coarsened exact matching*).

Errore standard fra parentesi tonde, p -value fra parentesi quadre. * $p < 0.10$, ** $p < 0.05$, *** $p < 0.01$.

8.2 Varianti di campione, controlli e variabile dipendente

La Tabella 11 raccoglie le variazioni sul *full panel*. Meritano un commento due righe in particolare.

Le righe “supporto comune” tengono solo i prodotti esportati sia verso destinazioni con accordo sia verso destinazioni senza. Per tutti gli altri non esiste un termine di paragone osservato, e confrontarli significherebbe estrapolare oltre i dati.

Le righe “quota verde nel paniere” cambiano proprio la domanda. Qui la variabile dipendente non è l’export ma la frazione di fatturato che l’impresa realizza in prodotti verdi verso quella destinazione. È il margine che i dati aggregati non possono vedere: l’impresa *ricompone* il proprio paniere quando il partner firma clausole ambientali? I coefficienti sono minuscoli e uno solo raggiunge la significatività convenzionale, con segno negativo: la riallocazione interna alle imprese non si osserva.

Tabella 11: Robustezza sul *full panel*: varianti di campione, controlli e variabile dipendente

Variante	× Verde	× Sporco	Osservazioni	R^2
Con controlli aggiuntivi (dazi, concentrazione, antidumping)	-0.00023 (0.00296) [0.938]	-0.00600** (0.00259) [0.022]	19,286,638	0.8736
Escludendo le 11 destinazioni ASEAN	-0.00252 (0.00360) [0.484]	-0.00438* (0.00223) [0.051]	19,236,090	0.8719
Reinserendo Hong Kong e Macao	-0.00089 (0.00360) [0.805]	-0.00409* (0.00243) [0.094]	23,560,110	0.8706
Solo prodotti con supporto comune	-0.00225 (0.00392) [0.567]	-0.00435* (0.00223) [0.052]	21,519,197	0.8734
Solo prodotti con supporto comune (indice TREND)	-0.00011 (0.00099) [0.914]	-0.00090 (0.00062) [0.153]	21,519,197	0.8734
Solo partner con accordo, profondi vs superficiali (TREND)	-0.00036 (0.00100) [0.723]	-0.00061 (0.00101) [0.549]	5,262,293	0.8839
Quota verde nel paniere dell’impresa (indice WB)	-0.00010 (0.00015) [0.503]		13,345,132	0.8510
Quota verde nel paniere dell’impresa (TREND)	-0.00006** (0.00003) [0.043]		13,345,132	0.8510

Variante baseline (escl. HK/Macao, controllo TotalDepth). Stima **reghdfe**; effetti fissi e raggruppamento come nella Tabella 3, salvo dove indicato.

Supporto comune: si tengono solo i prodotti che vengono esportati sia verso destinazioni con accordo sia verso destinazioni senza. Per gli altri non esiste un termine di paragone osservato.

Quota verde nel paniere: qui la variabile dipendente cambia. Non è più l’export, ma la frazione di fatturato che l’impresa realizza in prodotti verdi verso quella destinazione. Effetti fissi impresa×destinazione e anno. Risponde a una domanda diversa: l’impresa *ricompone* il proprio paniere?

Errore standard fra parentesi tonde, p -value fra parentesi quadre. * $p < 0.10$, ** $p < 0.05$, *** $p < 0.01$.

8.3 Andamenti specifici per destinazione e pre-trend

L’obiezione più seria a tutto il disegno. Gli effetti fissi assorbono moltissimo, ma non catturano una cosa: uno shock che riguardi *i prodotti verdi in una specifica destinazione* e che cresca nel tempo. È lo scenario in cui un paese firma clausole ambientali proprio mentre la sua domanda di beni verdi sta salendo per ragioni sue. In quel caso il coefficiente misurerebbe la domanda, non l’effetto delle clausole.

La risposta (Tabella 12, pannello A). Si aggiunge un andamento lineare per ogni combinazione destinazione–tipo di prodotto, che assorbe esattamente quella dinamica. È un controllo esigente, perché consuma molta della variazione disponibile.

Il pannello B testa formalmente la pendenza del divario di composizione nel periodo precedente l’accordo, riportando il p -value bootstrap.

Una nota di direzione. Vale la pena osservare che questo tipo di distorsione, se presente, spingerebbe il coefficiente sul margine verde verso l’alto: il risultato nullo osservato sarebbe quindi, semmai, un limite superiore. È un argomento a favore della robustezza della conclusione, e conviene esplicitarlo.

Tabella 12: Andamenti specifici per destinazione e verifica dei pre-trend

	(1)	(2)	(3)	(4)
<i>Pannello A — stima con andamenti lineari destinazione×tipo di prodotto (indice WB)</i>				
Profondità EP × Verde	-0.00510 (0.00360) [0.494]	-0.00200 (0.00436) [0.808]	0.00084 (0.00434) [0.896]	-0.00006 (0.00441) [0.995]
Profondità EP × Sporco	-0.00825 (0.00423) [0.275]	-0.00927 (0.00414) [0.249]	-0.01030* (0.00239) [0.086]	-0.00930** (0.00204) [0.037]
<i>Pannello A bis — stessa stima, indice TREND</i>				
Conteggio EP × Verde	-0.00217** (0.00062) [0.015]	-0.00214** (0.00061) [0.018]	-0.00111 (0.00053) [0.218]	-0.00153* (0.00049) [0.074]
Conteggio EP × Sporco	-0.00137 (0.00115) [0.355]	-0.00142 (0.00114) [0.339]	-0.00231** (0.00066) [0.048]	-0.00164 (0.00064) [0.109]
<i>Pannello B — test formale sui pre-trend (indice WB)</i>				
Pendenza pre-accordo, Verde	0.01732 (0.01295)	0.00402 (0.01678)	0.01719 (0.00997)	0.02218 (0.01346)
<i>p</i> -value bootstrap	0.678	0.705	0.543	0.497
Pendenza pre-accordo, Sporco	0.06292 (0.04393)	0.06237 (0.03983)	0.07109 (0.03161)	0.07056 (0.03159)
<i>p</i> -value bootstrap	0.610	0.515	0.416	0.410
<i>Pannello B bis — test formale sui pre-trend (indice TREND)</i>				
Pendenza pre-accordo, Verde	0.00728 (0.00438)	0.00707 (0.00441)	0.00775 (0.00428)	0.00944* (0.00389)
<i>p</i> -value bootstrap	0.189	0.199	0.173	0.090
Pendenza pre-accordo, Sporco	0.01512 (0.00728)	0.01512 (0.00721)	0.01839 (0.00596)	0.01703 (0.00613)
<i>p</i> -value bootstrap	0.293	0.301	0.164	0.243

Colonne: (1) Escl. HK/Macao, controllo TotalDepth (baseline); (2) Incl. HK/Macao, controllo TotalDepth; (3) Escl. HK/Macao, controllo DESTA; (4) Incl. HK/Macao, controllo DESTA.

Tutti i *p*-value e le stelle in questa tabella vengono dal *wild cluster bootstrap*, l'unico affidabile con il numero di cluster trattati disponibile (circa 25).

Pannello A/A bis — a quale obiezione risponde. Gli effetti fissi del disegno principale non catturano una cosa: uno shock che riguardi *i prodotti verdi in una specifica destinazione* e che cresca nel tempo. È il caso in cui un paese firma clausole ambientali proprio mentre la sua domanda di beni verdi sta salendo. Qui si aggiunge un andamento lineare per ogni destinazione e per ogni tipo di prodotto, che assorbe esattamente quella dinamica.

Il risultato con l'indice TREND. Nel Pannello A bis, il margine verde con l'indice TREND è l'unico coefficiente dell'intero lavoro a sopravvivere al bootstrap in modo netto ($p = 0.013$ nella colonna baseline). Il Pannello B bis mostra però che, con lo stesso indice, il divario verde era già positivo *prima* dell'entrata in vigore dell'accordo, sebbene non significativo al bootstrap: il risultato è quindi compatibile con una tendenza preesistente più che con un effetto causale dell'accordo, e va letto con questa cautela.

Pannello B/B bis — come si legge. Si stima la pendenza del divario di composizione nel periodo *precedente* all'accordo. Se fosse diversa da zero, verdi e neutri divergevano già prima e il confronto sarebbe viziato.

Errore standard fra parentesi tonde, *p*-value fra parentesi quadre. * $p < 0.10$, ** $p < 0.05$, *** $p < 0.01$.

8.4 Il modo in cui si controlla la profondità dell'accordo

Questa tabella merita attenzione perché mostra il punto più delicato di tutto il lavoro. Il controllo per la profondità complessiva è necessario — senza, il contenuto ambientale si prenderebbe il merito dell'accordo intero — ma è anche fortemente correlato con la variabile di interesse, e quindi ne assorbe parte della variazione.

La Tabella 13 mostra quattro modi di affrontare il problema: il controllo standard, nessun controllo, un controllo ristretto alle sole aree dell'accordo che potrebbero plausibilmente interagire con la composizione, e infine un cambio di impostazione — la *quota* ambientale sul totale, stimata solo fra i partner che hanno già un accordo. Quest'ultima riga è su una scala diversa e non va confrontata in valore assoluto con le altre.

Tabella 13: Quanto conta il modo in cui si controlla la profondità complessiva dell'accordo

Specificazione	× Verde	× Sporco
(a) Baseline: controllo TotalDepth	-0.00457 (0.00696) [0.512]	-0.01187*** (0.00295) [<0.001]
(b) Senza alcun controllo di profondità	-0.00572* (0.00309) [0.066]	-0.00368 (0.00254) [0.149]
(c) Controllo mirato alle sole aree rilevanti	-0.00327 (0.00793) [0.680]	-0.01212*** (0.00351) [<0.001]
(d) Quota ambientale sul totale, solo trattati	-2.25244* (1.14751) [0.063]	-1.59573 (1.55161) [0.315]

Indice WB, variante baseline, pannello collassato.

Il problema. Gli accordi con molte clausole ambientali sono spesso accordi profondi *in tutto*. Se non si tiene conto della profondità complessiva, si rischia di attribuire al contenuto ambientale un effetto che appartiene all'accordo nel suo insieme. Ma il controllo è a sua volta molto correlato con la variabile di interesse (0.959 al netto degli effetti fissi), quindi ne assorbe parte della variazione.

Le righe mostrano quanto il risultato dipenda da questa scelta: (b) toglie del tutto il controllo, (c) lo restringe alle sole aree dell'accordo che potrebbero plausibilmente interagire con la composizione, (d) cambia impostazione e misura la *quota* ambientale sul totale, stimata solo fra i partner che hanno già un accordo.

In (d) i coefficienti sono su una scala diversa (la quota varia fra 0 e 1) e non sono confrontabili in valore assoluto con le altre righe.

Errore standard fra parentesi tonde, *p*-value fra parentesi quadre. * $p < 0.10$, ** $p < 0.05$, *** $p < 0.01$.

8.5 Una definizione alternativa di “bene verde”

Non esiste una definizione univoca di bene ambientale. Il lavoro usa la lista OCSE, la più ampia e curata; la Tabella 14 la sostituisce con la lista APEC, molto più ristretta e frutto di un accordo politico del 2012. Se il risultato dipendesse da quali prodotti decidiamo di chiamare verdi, le due colonne divergerebbero.

Tabella 14: Definizione alternativa di bene ambientale: lista OCSE contro lista APEC

	Lista OCSE (usata nel lavoro)	Lista APEC (54 codici)
Profondità EP (WB) $\times$ Verde	-0.00457 (0.00696) [0.512]	0.00501 (0.01266) [0.693]
Conteggio EP (TREND) $\times$ Verde	0.00181 (0.00182) [0.320]	0.00319 (0.00208) [0.126]

Variante baseline, pannello collassato.

A cosa serve. Non esiste una definizione unica di “bene ambientale”. Il lavoro usa la lista OCSE; qui la si sostituisce con la lista APEC, molto più ristretta e concordata politicamente nel 2012. Se il risultato dipendesse da quali prodotti chiamiamo verdi, le due colonne divergerebbero.

Errore standard fra parentesi tonde, p -value fra parentesi quadre. * $p < 0.10$, ** $p < 0.05$, *** $p < 0.01$.

9 Il meccanismo: quali clausole potrebbero mordere

L’obiezione, che è sensata. Un indice che somma tutte le disposizioni mette insieme cose molto diverse: clausole che abbassano i dazi sui beni verdi o impongono standard vincolanti, e dichiarazioni di intenti senza alcun meccanismo. Se un effetto esiste, dovrebbe concentrarsi nelle prime. Sommando tutto si diluirebbe fino a sparire.

La verifica (Tabella 15). Si rifa la stima principale sostituendo l’indice complessivo con un sotto-indice alla volta.

Il risultato, che è esso stesso una scoperta. Negli accordi cinesi del periodo le disposizioni dotate di un meccanismo commerciale sono rarissime. I due sotto-indici della Banca Mondiale che ne hanno uno risultano diversi da zero in soli tre anni-paese e sono perfettamente sovrapposti fra loro: non è possibile distinguerne gli effetti. Non per un difetto del metodo, ma perché quel contenuto negli accordi *quasi non c’è*.

Perché questo cambia la conclusione del lavoro. Non si sta dimostrando che le clausole ambientali non funzionano mai. Si sta dimostrando che gli accordi cinesi del 2000–2015 contenevano quasi esclusivamente linguaggio di cooperazione, e che quel tipo di linguaggio non sposta il commercio. È un’affermazione più circoscritta ma più utile, e soprattutto è quella che i dati sostengono davvero.

Le righe “sola cooperazione” e “spazio regolatorio” (indice TREND) funzionano da controllo negativo: sono clausole prive di meccanismo commerciale. **Un’anomalia da dichiarare.** La riga “spazio regolatorio” risulta significativa su entrambi i margini ($p < 0,05$ su verde e sporco) con coefficienti positivi, il segno opposto alle attese.

La verifica richiesta è stata fatta, e il risultato regge (script 20b_wcb_regulatoryspace.R, 2026-08-14). Sotto *wild cluster bootstrap* ($B = 9.999$, cluster a destinazione) i due coefficienti restano significativi: $+0,0242$ sul verde con $p_{wcb} = 0,046$ e intervallo $[+0,003; +0,046]$; $+0,0225$ sullo sporco con $p_{wcb} = 0,022$ e intervallo $[+0,003; +0,042]$. Nessuno dei due intervalli contiene lo zero. Il controllo negativo, quindi, **non passa**, e va detto: è l’unico punto del lavoro in cui una clausola priva di meccanismo commerciale mostra un segnale che l’inferenza robusta non cancella.

Due elementi delimitano però quanto se ne può dedurre. **Primo:** i due margini si muovono *insieme*. Il differenziale verde meno sporco vale $+0,0017$ con $p = 0,80$ (test di Wald, $\chi^2 = 0,06$): verde e sporco salgono della stessa quantità rispetto ai prodotti neutri. Non è la firma di uno spostamento di composizione verso i prodotti puliti — che è l’oggetto misurato qui — ma di qualcosa che muove entrambe le categorie contro la base neutra. **Secondo, e più decisivo:** questo sotto-indice non è un controllo negativo pulito in partenza. Lo “spazio regolatorio” vale il **71,5%** del conteggio TREND sugli anni-paese trattati e correla **0,90** con il controllo di profondità complessiva; e in questa stessa specifica il controllo di profondità diventa a sua volta significativo, ma di segno opposto ($-0,0011$ sul verde, $p = 0,006$). Due regressori correlati a 0,90 che si spartiscono la varianza in un positivo grande e un negativo grande sono il problema di *bundling* descritto in questa stessa sezione, applicato al controllo negativo — non un canale indipendente misurato bene.

La conclusione difendibile è quindi più debole, e va scritta così: questo disegno non riesce a separare un effetto dello “spazio regolatorio” dalla profondità generale dell’accordo, e di conseguenza non può nemmeno usarlo come test di falsificazione pulito. Resta un limite dichiarato, non un risultato né un’assoluzione.

Due avvertenze sulle stelle di questa tabella. (i) I p -value sono asintotici e su questo numero di cluster sono inaffidabili per le stesse ragioni illustrate in Tabella 18. (ii) La riga `WB_GreenLiberalization` è una variabile binaria non nulla in soli tre anni-paese: il coefficiente ($-0,088^*$) non è un effetto marginale per clausola ma un confronto fra i tre anni con l’accordo e tutti gli altri; la colonna è su scala incomparabile con le righe degli indici continui.

Tabella 15: Scomposizione per tipo di disposizione: quali clausole avrebbero un meccanismo commerciale?

Sotto-indice	× Verde	× Sporco
Liberalizzazione dei beni verdi (WB)	-0.0115 (0.0879) [0.896]	-0.0876* (0.0483) [0.071]
Accesso al mercato per i beni verdi (TREND)	-0.0271 (0.0303) [0.372]	-0.0491** (0.0243) [0.045]
Meccanismo di risoluzione controversie (WB)	-0.0048 (0.0394) [0.903]	0.0067 (0.0525) [0.898]
Meccanismo di risoluzione controversie (TREND)	0.0042 (0.0148) [0.778]	-0.0052 (0.0140) [0.709]
Disposizioni vincolanti (TREND)	0.0022 (0.0047) [0.638]	-0.0013 (0.0037) [0.724]
Disposizioni di sola cooperazione (TREND)	0.0132 (0.0121) [0.275]	0.0019 (0.0108) [0.858]
Clausole di spazio regolatorio (TREND)	0.0242** (0.0099) [0.015]	0.0225*** (0.0086) [0.010]
Celle (tutte le righe)	3,681,023	

Variante baseline, pannello collassato. Ogni riga è una stima separata in cui l'indice complessivo è sostituito dal sotto-indice indicato; il controllo di profondità resta incluso.

L'obiezione a cui risponde. Un indice che somma tutte le disposizioni mescola clausole che potrebbero davvero spostare il commercio (abbassare i dazi sui beni verdi, imporre standard vincolanti) con dichiarazioni di intenti che non hanno alcun meccanismo. Se l'effetto esiste, dovrebbe concentrarsi nelle prime.

Il limite, che è esso stesso un risultato. Negli accordi cinesi del periodo le disposizioni dotate di un meccanismo commerciale sono rarissime: i due sotto-indici della Banca Mondiale che ne hanno uno sono diversi da zero in soli tre anni-paese e risultano perfettamente sovrapposti fra loro. Non è quindi possibile distinguerne gli effetti: non per un difetto del metodo, ma perché quel contenuto negli accordi quasi non c'è.

Le righe *sola cooperazione* e *spazio regolatorio* funzionano da controllo negativo: sono clausole senza meccanismo commerciale, e lì non dovrebbe emergere nulla.

Errore standard fra parentesi tonde, p -value fra parentesi quadre. * $p < 0.10$,

** $p < 0.05$, *** $p < 0.01$.

10 I margini che le stime principali non vedono

10.1 Nascono flussi nuovi?

Il limite delle stime in logaritmo. Il logaritmo di zero non esiste: le stime precedenti usano solo i flussi commerciali già esistenti. Se una clausola ambientale facesse *nascere* esportazioni verdi verso un mercato dove prima non ce n'erano, quelle stime non lo vedrebbero.

La soluzione (Tabella 16). Si costruisce una griglia completa prodotto–destinazione–anno, si riempiono con zeri le combinazioni senza scambi, e si stima con il metodo di Poisson pseudo-massima verosimiglianza, che tratta gli zeri correttamente.

Che cosa dicono i numeri. Nessuna creazione di commercio verde: i coefficienti sul margine verde sono minuscoli e non significativi in tutte le varianti.

Tabella 16: Margine estensivo: nascono flussi commerciali che prima non c'erano?

	(1)	(2)	(3)	(4)
<i>Pannello A — indice WB</i>				
Profondità EP × Verde	0.0015 (0.0046) [0.738]	0.0029 (0.0061) [0.630]	0.0053 (0.0045) [0.234]	0.0064 (0.0050) [0.207]
Profondità EP × Sporco	-0.0301* (0.0158) [0.057]	-0.0268 (0.0178) [0.133]	-0.0186 (0.0170) [0.273]	-0.0108 (0.0199) [0.586]
<i>Pannello B — indice TREND</i>				
Conteggio EP × Verde	0.0001 (0.0019) [0.951]		0.0010 (0.0013) [0.444]	0.0008 (0.0015) [0.567]
Conteggio EP × Sporco	0.0028 (0.0047) [0.550]		0.0027 (0.0053) [0.614]	0.0046 (0.0050) [0.360]
Celle (con zeri)	7,895,543	8,030,137	7,878,784	8,003,772

Colonne: (1) Escl. HK/Macao, controllo TotalDepth (baseline); (2) Incl. HK/Macao, controllo TotalDepth; (3) Escl. HK/Macao, controllo DESTA; (4) Incl. HK/Macao, controllo DESTA.

Stima Poisson pseudo-massima verosimiglianza (PPML) su una griglia prodotto–destinazione–anno completata con gli zeri; effetti fissi prod.×dest., dest.×anno, prod.×anno; errori raggruppati per destinazione.

Perché serve. Le stime in logaritmo usano solo i flussi già esistenti: se una clausola ambientale facesse *nascere* esportazioni verdi verso un mercato dove prima non ce n'erano, quelle stime non lo vedrebbero. Il PPML tiene dentro anche gli zeri e quindi coglie questo margine.

I coefficienti PPML si leggono come variazioni percentuali approssimate.

Errore standard fra parentesi tonde, *p*-value fra parentesi quadre. * $p < 0.10$,

** $p < 0.05$, *** $p < 0.01$.

10.2 Una misura continua di inquinamento

L’obiezione. Classificare un prodotto come sporco sì o no è grossolano: l’acciaio e la carta non inquinano allo stesso modo. Una classificazione binaria introduce inoltre errore di misura, che tende a schiacciare i coefficienti verso zero.

La verifica (Tabella 17). Si sostituisce la variabile binaria con una misura continua di intensità di emissioni per settore, così i prodotti si ordinano lungo una scala invece che in due caselle.

Tabella 17: Misura continua di intensità inquinante al posto della classificazione sì/no

	(1)	(2)	(3)	(4)
<i>Pannello A — indice WB</i>				
Profondità EP × Verde	-0.00503 (0.00698)	0.00044 (0.00804)	-0.00248 (0.00489)	-0.00414 (0.00553)
<i>p</i> -value bootstrap	0.544	0.961	0.797	0.797
Profondità EP × Intensità CO ₂	-0.00255 (0.00566)	-0.00485 (0.00639)	0.00128 (0.00308)	0.00280 (0.00314)
<i>p</i> -value bootstrap	0.707	0.529	0.773	0.384
<i>Pannello B — indice TREND</i>				
Conteggio EP × Verde	0.00088 (0.00170)	0.00086 (0.00172)	0.00106 (0.00176)	-0.00002 (0.00170)
<i>p</i> -value bootstrap	0.677	0.698	0.652	0.993
Conteggio EP × Intensità CO ₂	-0.00131** (0.00051)	-0.00136** (0.00054)	-0.00083** (0.00038)	-0.00018 (0.00064)
<i>p</i> -value bootstrap	0.063	0.056	0.083	0.817

Colonne: (1) Escl. HK/Macao, controllo TotalDepth (baseline); (2) Incl. HK/Macao, controllo TotalDepth; (3) Escl. HK/Macao, controllo DESTA; (4) Incl. HK/Macao, controllo DESTA.

L’obiezione a cui risponde. Classificare un prodotto come “sporco” sì o no è grossolano: l’acciaio e la carta non inquinano allo stesso modo. Qui la variabile binaria è sostituita da una misura continua di intensità di CO₂ per settore, così i prodotti si ordinano lungo una scala invece che in due caselle.

Un coefficiente negativo significherebbe che, dove il contenuto ambientale è più profondo, le esportazioni calano di più per i prodotti più inquinanti.

Si riporta anche il *p*-value bootstrap perché, come altrove, quello ordinario è troppo generoso con così pochi gruppi trattati.

Errore standard fra parentesi tonde, *p*-value fra parentesi quadre. * $p < 0.10$, ** $p < 0.05$, *** $p < 0.01$.

11 Il risultato dipende da un solo paese?

Il rischio. Con circa quattordici accordi, un singolo partner molto grande può generare da solo tutto il risultato. Sarebbe una conclusione fragile, e soprattutto una conclusione su quel paese e non sul fenomeno.

La prova (Tabella 18). Si ristima la specificazione escludendo ogni volta una destinazione trattata, e si guarda che cosa resta del coefficiente.

Come si legge. Questa tabella misura la *stabilità del coefficiente*, non la sua significatività: la domanda è di quanto si sposta il numero quando si toglie un paese, non quante stelle porta. Nella colonna (1) il coefficiente oscilla fra $-0,0097$ e $-0,0133$ senza mai cambiare segno: nessun singolo partner genera il risultato. I paesi che pesano di più sono Corea e Australia nella colonna (1), e Hong Kong nella colonna (2). Le colonne (2) e (4) hanno due righe in più perché includono Hong Kong e Macao.

In che modo “pesano”, però. Non spostando la stima, ma distruggendone la precisione — ed è una differenza sostanziale. Togliendo l’Australia dalla colonna (1) il coefficiente si muove del 13% (da $-0,0119$ a $-0,0103$), ma il suo errore standard quasi *triplica*, da $0,0030$ a $0,0087$: è questo, non lo spostamento del punto, a portare il p a $0,24$. Togliendo la Corea l’errore standard raddoppia. Per confronto, togliendo India o Pakistan il coefficiente si muove dell’1–4% e l’errore standard resta dov’era. Australia e Corea non sono quindi casi anomali che tirano la stima da una parte: sono i paesi che forniscono gran parte della variazione con cui il modello è identificato. Toglierli non dà una risposta diversa, lascia il disegno senza abbastanza informazione per darne una.

E quale paese sia decisivo dipende dal controllo di profondità. Nella colonna (1) è l’Australia; nella colonna (3), che usa DESTA al posto di TotalDepth, togliere l’Australia lascia il coefficiente a $-0,0110$ con $p = 0,001$, mentre è la Corea a triplicare l’errore standard ($p = 0,14$). Da che cosa dipenda il risultato è dunque a sua volta funzione di una scelta di modellazione che non ha niente a che vedere con il contenuto ambientale misurato. È un argomento in più a favore della lettura “fragile”, non una contraddizione.

La colonna (4) merita attenzione a parte. È la più instabile: togliere l’Australia sposta il coefficiente da $-0,0082$ a $-0,0048$ (-41%); togliere il Pakistan lo porta a $-0,0056$. Chi usa questa colonna per argomentare dovrebbe documentarlo esplicitamente.

Perché qui è quasi tutto stellato. Gli asterischi di questa tabella vengono dai p -value asintotici prodotti dallo stimatore, non dal *wild cluster bootstrap* usato in tutto il resto del documento. Con circa ventitré destinazioni trattate quei p -value sono enormemente sottostimati: la riga di riferimento della colonna (1) ha p asintotico inferiore a $0,001$, ma il *bootstrap* sullo stesso identico coefficiente dà $0,070$ (Tabella 5). Le stelle vanno quindi ignorate: sono un artefatto dello stesso problema di pochi cluster trattati che il resto del lavoro è costruito per gestire.

Una lacuna che non c’è più. Fino alla campagna di replica in Stata i file esportati per questa prova contenevano soltanto coefficiente e p -value, e la lettura sopra — quella sugli errori standard — non era nemmeno possibile. Ora `63_variants_collapsed.do` scrive anche errore standard, numerosità e numero di cluster per ogni riga e per tutte e quattro le colonne. È il caso in cui completare un export ha cambiato che cosa si riesce a dire, non solo da dove viene il numero.

Tabella 18: Prova di esclusione: che cosa resta del risultato togliendo un paese alla volta

Paese escluso	(1)	(2)	(3)	(4)
<i>Nessuno (riferimento)</i>	-0.0119***	-0.0189***	-0.0113***	-0.0082*
<i>Nessuno, lista sporchi estesa</i>	-0.0121***	-0.0191***	-0.0107***	-0.0071
alta_dose	-0.0271**	-0.0456***	-0.0161	-0.0164
Bangladesh	-0.0118***	-0.0188***	-0.0113***	-0.0082*
Brunei	-0.0119***	-0.0189***	-0.0114***	-0.0082*
Myanmar	-0.0118***	-0.0188***	-0.0112***	-0.0081*
Cambodia	-0.0119***	-0.0189***	-0.0112***	-0.0081*
India	-0.0120***	-0.0190***	-0.0115***	-0.0084**
Indonesia	-0.0119***	-0.0190***	-0.0119***	-0.0087**
Laos,PDR	-0.0119***	-0.0189***	-0.0113***	-0.0082*
Malaysia	-0.0124***	-0.0195***	-0.0110***	-0.0076*
Pakistan	-0.0114***	-0.0183***	-0.0106***	-0.0056
Philippines	-0.0118***	-0.0189***	-0.0115***	-0.0083*
Singapore	-0.0098**	-0.0166***	-0.0128***	-0.0100**
Korea Rep.	-0.0097*	-0.0225**	-0.0104	-0.0085
Sri Lanka	-0.0119***	-0.0189***	-0.0114***	-0.0082*
Thailand	-0.0120***	-0.0189***	-0.0115***	-0.0083*
Vietnam	-0.0122***	-0.0192***	-0.0112***	-0.0080*
East Timor	-0.0119***	-0.0189***		
Iceland	-0.0119***	-0.0189***	-0.0112***	-0.0081*
Switzerland	-0.0133***	-0.0209***	-0.0115***	-0.0084*
Chile	-0.0121***	-0.0191***	-0.0104***	-0.0071
Costa Rica	-0.0114***	-0.0185***	-0.0109***	-0.0076*
Peru	-0.0133***	-0.0204***	-0.0121***	-0.0092**
Australia	-0.0103	-0.0245**	-0.0110***	-0.0048
New Zealand	-0.0119***	-0.0190***	-0.0113***	-0.0081*
HongKong		-0.0129***		-0.0112***
Macau		-0.0183***		-0.0082*

Colonne: (1) Escl. HK/Macao, controllo TotalDepth (baseline); (2) Incl. HK/Macao, controllo TotalDepth; (3) Escl. HK/Macao, controllo DESTA; (4) Incl. HK/Macao, controllo DESTA.

Coefficiente dell'interazione fra profondità ambientale (WB) e prodotti sporchi, pannello collassato, ristimato escludendo ogni volta una destinazione trattata.

A cosa serve. Con pochi accordi, un singolo partner molto grande può generare da solo tutto il risultato. Se il coefficiente crolla togliendo un paese, la conclusione poggia su quel paese e non sul fenomeno generale.

Come si legge. Questa è una prova di *stabilità del coefficiente*, non di significatività: si guarda di quanto si sposta il numero, non quante stelle ha. Righe in cui il coefficiente si dimezza o cambia segno segnalano i paesi da cui il risultato dipende di più.

Avvertenza sulle stelle. Gli asterischi derivano dai p -value asintotici con cluster per destinazione prodotti dallo stimatore, non dal *wild cluster bootstrap* usato altrove. Con circa 23 destinazioni trattate quei p -value sono fortemente sottostimati: lo stesso coefficiente di riferimento della colonna (1) ha p asintotico <0.001 ma p bootstrap 0.070 (Tabella 5). Le stelle di questa tabella non sono quindi confrontabili con quelle del resto del documento e non vanno lette come evidenza di significatività.

Le righe di Hong Kong e Macao sono vuote nelle colonne (1) e (3) perché in quelle varianti i due territori sono già esclusi dal campione: non si possono togliere due volte.

Gli errori standard e il numero di osservazioni non sono presenti nei file esportati per questa prova: è una lacuna nota degli export, non un dato mancante.

* $p < 0.10$, ** $p < 0.05$, *** $p < 0.01$.

12 Che cosa possiamo davvero escludere

Perché questa è la tabella più importante di tutte. Un risultato nullo può significare due cose molto diverse: che l'effetto non esiste, oppure che esiste ma è troppo piccolo perché questi dati riescano a distinguerlo dal rumore. Senza rispondere a questa domanda, un “non abbiamo trovato nulla” non è informativo.

Che cosa è stato calcolato (Tabella 19). L'*effetto minimo rilevabile*: la dimensione al di sotto della quale il disegno non è in grado di dire nulla. Viene riportato sia nella versione basata sulla formula asintotica sia in quella basata sull'intervallo bootstrap, che è la più onesta perché corrisponde all'inferenza effettivamente usata.

Che cosa dicono i numeri. Sull'unità collassata l'intervallo bootstrap del margine verde è $[-1,8\%, +3,2\%]$ per disposizione: fuori da quel range l'effetto è escluso al 95%, dentro il disegno non discrimina. La soglia è *asimmetrica* — il disegno esclude meglio i grandi effetti positivi che i grandi effetti negativi.

Sul *full panel*, che è la specificazione di riferimento, l'intervallo bootstrap è più largo e quasi simmetrico: $[-3,5\%, +3,6\%]$ per disposizione. È questa la cifra da usare quando si parla di precisione del lavoro nel suo complesso. Va segnalato che l'intervallo *asintotico* corrispondente, $[-1,0\%, +0,55\%]$, è circa sei volte più stretto: costruire su quello un'affermazione di precisione significherebbe rivendere esattamente la certezza che la sezione sull'inferenza dichiara ingiustificata con ventitré cluster trattati. Le due cifre non vanno mescolate.

La riformulazione che ne discende. Nel testo del lavoro conviene sostituire ovunque “non troviamo alcun effetto” con “possiamo escludere effetti superiori a questa soglia”. È più preciso, più difendibile e, paradossalmente, più forte.

Tabella 19: Quanto dovrebbe essere grande un effetto perché questo disegno riuscisse a vederlo

Indice	Margine	Errore std. asintotico	Effetto minimo rilevabile (1 dev. std.)	Semi-ampiezza IC bootstrap (1 dev. std.)	Intervallo di confidenza bootstrap (per unità)
WB	Verde	0.0070	4.64%	5.90%	$[-1.77\%, 3.19\%]$
WB	Sporco	0.0030	1.97%	2.40%	$[-1.84\%, 0.18\%]$
TREND	Verde	0.0018	4.16%	3.62%	$[-0.18\%, 0.71\%]$
TREND	Sporco	0.0016	3.65%	3.53%	$[-0.32\%, 0.54\%]$

Campione di stima: pannello collassato, variante escl. HK/Macao. Deviazione standard dei regressori calcolata sul campione effettivo e pesata.

Perché questa tabella è importante. Un risultato nullo può significare due cose molto diverse: che l'effetto non c'è, oppure che c'è ma è troppo piccolo perché i dati lo distinguano dal rumore. Questa tabella dice quale delle due.

Come si legge. L'*effetto minimo rilevabile* (quarta colonna) è la dimensione al di sotto della quale il disegno non è in grado di dire nulla, calcolato sul metodo asintotico ($2,8 \times$ errore standard). La quinta colonna riporta la semi-ampiezza dell'intervallo di confidenza *wild cluster bootstrap*: non è un MDE a potenza 80% (sarebbe $1,43 \times$ più grande), ma il margine d'errore bootstrap. Il bound informativo per la stima di precisione è la colonna [IC WCB]: sul margine verde, esclude effetti superiori a circa il 3% per disposizione al 95% di confidenza.

Ne discende una formulazione più corretta del risultato: non “non troviamo alcun effetto”, ma “possiamo escludere effetti superiori a questa soglia”.

13 Che cosa dicono tutte insieme

Sul margine verde la risposta è netta. Le clausole ambientali degli accordi cinesi non hanno aumentato le esportazioni di beni ambientali rispetto ai prodotti neutri. Il coefficiente è prossimo a zero in tutte e quattro le varianti, in entrambe le unità di analisi, con tutti e tre i metodi di inferenza, con tre gruppi di controllo alternativi, con una definizione alternativa di bene verde e sul margine estensivo. (La quota verde *interna* alle imprese punta nella stessa direzione, ma va tenuta fuori da questo elenco: quella specificazione è in livello e non ha gli effetti fissi $\text{impresa} \times \text{destinazione} \times \text{anno}$, quindi non identifica nulla — vale come descrizione, non come conferma.) È il risultato più solido del lavoro, e la Tabella 19 permette di enunciarlo nella forma corretta: al 95% di confidenza sono esclusi effetti superiori a +3,2% per disposizione sull'unità collassata e a +3,6% sul *full panel* — che è la soglia da citare, essendo il *full panel* la specificazione di riferimento. Sotto quella soglia il disegno non discrimina, e questo va detto insieme al resto.

Sul margine sporco la risposta è più sfumata, e va detta come tale. Il coefficiente è negativo nella grande maggioranza delle specificazioni, ma non in tutte: sotto il gruppo di controllo più stretto (prodotti della stessa famiglia HS4, prima riga di Tabella 10) il segno si inverte. La sua significatività statistica dipende inoltre da due scelte: l'unità di analisi e, soprattutto, quale misura si usa per controllare la profondità complessiva dell'accordo. Con il controllo della Banca Mondiale, che è quello della specificazione di riferimento, il *p*-value bootstrap sul *full panel* resta sopra 0,17. Con il controllo DESTA scende sotto 0,05. Presentare solo la seconda cifra sarebbe scorretto; presentare solo la prima trascurerebbe un'informazione reale.

La spiegazione più probabile del perché le clausole non mordano viene dalla Tabella 15: negli accordi cinesi del periodo il contenuto ambientale è quasi interamente linguaggio di cooperazione, privo di meccanismi commerciali. Le poche disposizioni che un meccanismo ce l'hanno compaiono in due soli accordi. La conclusione difendibile non è quindi “le clausole ambientali non servono”, ma: *i capitoli ambientali basati sulla cooperazione — che sono il contenuto tipico di questi e di molti altri accordi — non modificano la composizione del commercio*. Per il dibattito su come rendere più verdi gli accordi commerciali, la distinzione conta parecchio: ciò che può spostare i flussi è il contenuto delle clausole, non la presenza di un capitolo ambientale.

Nota sulla riproducibilità. Tutte le tabelle di questo documento sono generate automaticamente dai file di risultato tramite lo script `New/Code/44_make_tables_tex.R`. Nessun numero è stato trascritto a mano. Due informazioni non sono però contenute nei file di risultato e sono state riportate a mano nelle note: la struttura degli effetti fissi e il livello di raggruppamento degli errori. Entrambe provengono dagli script di stima; se uno script cambia, va aggiornata la costante corrispondente nel generatore.